

AI幫您擬定最適行銷預算分配戰略

當談及行銷預算時，通常會想到的是行銷預算分配可以根據公司的目標和需求進行調整。一般來說，行銷預算可以分配到不同的行銷通路上，例如：廣告、公關、內容行銷、社群媒體行銷等。預算分配的比例也可依據公司的目標和預期效益進行調整。如果公司的目標是增加品牌知名度與曝光度，那麼在品牌形象的媒體廣告支出的比重可能就較高，例如，奧美廣告公司為全聯製作的「經濟美學系列影片」，即是在用各種「金句」打造一種全聯在生活無所不在的觀感，吸引更多消費者至全聯購物；如果目標是提高銷售額，那麼像是內容行銷和社群媒體行銷就更加重要了。

上次Jasper經歷過主題1精準行銷的洗禮後，接著又遇到了難題，便回饋給筆者：「上次的精準行銷操確實有協助企業增長商品利潤率與舊客回頭率，不過我們這次遇到的難題是...」

為了方便讀者閱讀，筆者點列呈現並讓讀者先睹為快本章難題：

1. 上個主題的A商品等其他重點商品具完整的CRM資料，但依然有不少商品僅有行銷通路在一段期間的費用與營收記錄，並無每一位顧客的詳盡資料，且資料通常僅有幾百筆，這樣也可以做分析嗎？
2. 推出的數位廣告和實體廣告，諸如：品牌行銷或雜誌廣告仍難以追蹤廣告效益（例如：ROAS，廣告投資報酬率），我們該如何知道廣告是否有效呢？
3. 我們可以能夠透過現有的通路花費資料來預測未來商品收益嗎？
4. 可以知道花費到多少錢就不用再打廣告了嗎？
5. 發佈每一則廣告後，在各通路可以維持多久的成效呢？
6. 是否能自動化分配不同廣告預算到不同通路？自動化的預算策略是否能夠超越人工預算分配策略？

於是筆者又開始與Jasper新一輪的合作。面臨上述挑戰，筆者將介紹如何使用機器學習技術來幫助Jasper回饋了上述疑問，同時協助Jasper自動化擬定最適行銷預算分配策略。筆者接下來將詳細說明公司行銷預算分配策略的決策過程與Python程式碼實作，讓讀者有一個全面的了解。

對了，Jasper最後還補了一句酸味十足的話語：「過往老總給我們的行銷預算，基本上我們都是按照直覺來分配的，哈哈！時好時壞，每次投廣告就想算命一樣，希望透過本次的學習與實作，我們可以不用再充當算命師了。」

相信多數人在做行銷通路預算分配時，也是在通靈與算命，但真的只能如此嗎？我們能善用所有幾乎所有企業都拿得出來的數據讓「通靈」與「算命」更加準確嗎？

壹、讓通靈與算命更準確？需要的資料沒想象中複雜！

擔任數據品質解決方案公司（Data Quality Solutions）總裁與奇異公司全球研究中心（GE Global Research）應用統計實驗室負責人的湯瑪斯·雷曼（Thomas C. Redman）與羅傑·賀爾（Roger W. Hoerl）於2019年的哈佛商業評論（HBR）上，發表了一篇文章〈大多數分析專案沒那麼需要大數據〉（Most Analytics Projects Don't Require Much Data）（Redman & Hoerl, 2019），內容提到小數據有助於讓人們得以快速取得相關資料，並且每個小數據專案在美國係有機會在每年產出1萬到25萬美元的財務收益。所以在Jasper所面臨做精準行銷數據量不足且數據蒐集成本有限的狀況下，首要的是要調整思維，切勿因數據量或數據資訊量不足而放棄，反而應優先重視該專案現有的數據品質是否堪以分析。

就算有不少商品僅有行銷通路在一段期間的費用與營收記錄，只要資料品質是優質且無污染的，就算該商品資料沒有包含每一位顧客的詳盡資料，也可以在資料僅有幾百筆的狀況下來做數據分析。

以本案為例，讀者可從圖1與2中知曉筆者為Jasper團隊所使用的資料形態僅包含簡單的每週行銷通路花費，如：Facebook、YouTube與Magazine每週花費；以及每週該商品的營收，總共200筆的資料。這樣即可分析上述疑問。同樣的，請讀者特別注意，本案提供的所有資料皆為非真實之模擬資料。

預算最佳化與銷售預測分析 – 資料說明



圖 1. 本案資料說明

資料形態

Date	Facebook	Youtube	Magazine	weekly revenue
2018-01-07	13528.1	0	0	127137.4
2018-01-14	0	5349.65	2218.93	172187.47
2018-01-21	0	4235.86	2046.96	156294.58
2018-01-28	0	3562.21	0	115010.35

Variables	Data type	Description
1.Date	Datetime	每一週商品行銷費用與營收的日期
2.Facebook	Float	每週花在 Facebook 廣告上的費用
3.YouTube	Float	每週在 YouTube廣告上的花費
4.Magazine	Float	每週在雜誌廣告上的花費
5.Weekly_revenue	Float	每週營收

圖 2. 本案資料形態

為了分別讀者理解，筆者也在此羅列本案情境，讓讀者更能有沉浸式體驗一同與筆者來分析本案：

1. 商品：Jasper團隊要行銷的B商品，本商品為家用類的科技產品，讀者可以自行想象與冰箱相似之中、大型科技產品。

2. 價格: \$45,000新台幣左右
3. 營收/成交通路: 98%皆是透過實體通路銷售, 僅有2%是從網路銷售出去
4. 行銷通路: 公司近4年建立了YouTube自媒體、Facebook社區等行銷通路, 同時也通過雜誌、廣告牌等實體行銷通路來行銷本商品。
5. 資料: 過去4年的去識別化模擬資料。

Jasper接著回饋:「原來如此! 雖然這些小資料不足以做之前合作過的精準行銷案件, 但有上述小數據原來就可以完成數據分析工作了!」

Jasper繼續問:「那接下來這些資料有辦法推估不同廣告, 例如品牌行銷或雜誌廣告, 這種難以評估廣告投資報酬率(ROAS)的廣告嗎? 雖然FB等廣告可以埋Pixel追蹤, 但是不少人會因為看過FB廣告與我們雜誌等廣告直接搜我們的產品然後購買, 所以這種狀況是否也能估計呢? 以便我們評估這些廣告到底有無效果。」

貳、不同的廣告效益如何追蹤? 廣告真的有效嗎?

首先, 我們需要再次與Jasper確認的是, 本次資料所有行銷費用與營收資料都與本次要分析的B商品皆有關聯, 也就是說資料品質是優質且乾淨的。經過Jasper的確認, 去除了與B商品無關聯的行銷費用後, 呈現在圖1的就是本次要分析的資料。

數據分析層面, 我們可以善用管理科系大學與研究所所學的「多元迴歸分析模型(multiple regression analysis model)」來判讀Jasper公司推出的數位品牌廣告或實體雜誌廣告的廣告投資報酬率(Return On Advertising Spend; ROAS)。

讓筆者用圖像化的方式來協助讀者回顧或介紹一下本章節即將使用的迴歸分析吧! 迴歸分析在本案的主要用途為「用行銷通路所劃分的廣告支出來預測和解釋每週營收」, 由圖3中, 讀者可知筆者即是將本案有的行銷通路Facebook、Magazine與YouTube當做是會「影響」週營收的特徵變數或稱自變數(independent variables), 藉此來探討三組行銷通路所花費的費用是否對週營收是有好的效果。而圖3的 β 係數(Beta或Coefficient)則代表的是不同行銷通路的ROAS, 故可透過Python開始估計ROAS。

多元迴歸分析 – 用廣告費用來預測與解釋營收

1. 多元迴歸的用途：用行銷通路的廣告支出來預測和解釋每週營收
2. 迴歸式： $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i + \beta_3 x_i + \varepsilon_i$
3. 本案迴歸式：
 $Weekly_revenue = \hat{\beta}_0 + \hat{\beta}_1 Facebook_i + \hat{\beta}_2 Magazine_i + \hat{\beta}_3 YouTube_i + \hat{\varepsilon}_i$



4

圖 3. 本案迴歸分析解釋圖

從本段開始，讀者可從下述 QR code 或從下述 GitHub repository 鏈接中找到 budgeting_forecast-marketing-roas-and-budget-optimization 資料夾，將其複製 (clone) 下來，一起隨筆者實作程式碼。



<https://github.com/HowardNTUST/ai-marketing-book>

(建構中，所以權限先設定 private)

在資料集中會發現有 4 個檔案，如圖 4 所示：

1. Results：包含了本章節的所有產出，有興趣的讀者可以先以裡面的檔案配合文章一同查看。
2. budgeting_main.py：為主要的 Python 執行檔案，請讀者可以直接打開這個檔案跟筆者一起操作與執行。

3. budgeting_lib.py：為本案自製的Python套件檔案（library）。
4. digital_marketing_raw.csv：為Jasper蒐集到的200筆B商品數位通路行銷費用與週營收資料。

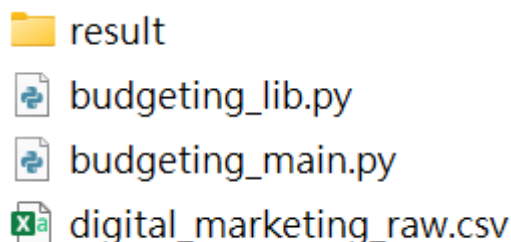


圖 4. budgeting_forecast-marketing-roas-and-budget-optimization 資料集包含的內容

有了上述資料後，首要解決的問題為找出「各行銷通路的ROAS」。在估計多元迴歸模型的係數前，統計模型通常會假設每一組係數的虛無假設等於0（Null hypothesis； H_0 ）；對應到對立假設（alternative hypothesis； H_1 ）不等於0，如方程式1所示。

$$H_0 = 0; H_1 \neq 0 \dots \text{方程式 1}$$

白話來說，即用多元迴歸模型來測試的每一組行銷通路的ROAS是否為0的狀態。若ROAS估計出來為0，則代表這個通路對週營收是沒有效用的，統計上則稱沒有達顯著（Statistical insignificance）的影響。如此不但能評估Jasper花費到三組通路的費用是否有效，亦能估計其ROAS之效用。

Jasper回應道：「哦哦！我懂了！就是我可以設定一個ROAS的倍數，然後用統計模型來評估是否有達到這個ROAS的效果，舉例來說，我可以設定YouTube的ROAS是否不等於0且為正的倍數，那這樣就代表有效果的概念啦！」

沒錯！確實如此！接著，請讀者開啟budgeting_main.py，並讀入程式碼1，照過往管理先產出與檢查其資料形態Excel表格，可發現其產出成果均為之前圖1所示，可見目前資料形態是為正常且可分析的資料，如程式碼1的產出所示。

程式碼 1

```
# %%  
# SECTION - 程式碼1  
import statsmodels.api as sm  
from budgeting_lib import *
```

```

import pandas as pd
import numpy as np
from sklearn.base import BaseEstimator, TransformerMixin
from sklearn.utils.validation import check_is_fitted, check_array

# 讀入檔案
X, y, data = load_data(data_path='digital_marketing_raw.csv',
                        drop_columns=['weekly_revenue', 'Date'],
                        y_column='weekly_revenue')

# 輸出 data.info() --> 將 data.dtypes 與 data.count() 合併
# 產出 X 的資料型態與非空值的資料筆數
data_type_X = pd.concat(
    [pd.DataFrame(X.dtypes), X.count()], axis=1).reset_index()

# 產出 y 的資料型態與非空值的資料筆數
y1 = pd.DataFrame(y)
data_type_y = pd.concat(
    [pd.DataFrame(y1.dtypes), y1.count()], axis=1).reset_index()

# 將 X 與 y 的資料型態與非空值的資料筆數合併
data_type = pd.concat(
    [data_type_X, data_type_y], axis=0)

# 產出欄位名稱與資料型態 Excel 檔案
data_type.columns = ['欄位名稱', '資料型態', '非空值的資料筆數']
data_type.to_excel('01_資料形態.xlsx', index=False)

# !SECTION 程式碼 1

```

產出成果

01_資料形態.xlsx

欄位名稱	資料型態	非空值的資料筆數
Facebook	float64	200
Youtube	float64	200
Magazine	float64	200
weekly_revenu	float64	200

從Jasper主領域知識與資料的角度確認完資料整潔度後，就可以開始第一項的ROAS估計分析啦！從程式碼2的產出成果來看，可得知不同行銷通路（marketing_channel）所對應的係數（coefficient）。結果而言，Facebook的ROAS平均達到4.7倍、YouTube達到6.4倍以及Magazine達到15.8倍。其皆有超過不等於0的對立假設，看來行銷是有效果的。

程式碼 2

```
# SECTION - 程式碼2
X_const = sm.add_constant(X, prepend=False)
model = sm.OLS(y, X_const)
results = model.fit()
print(results.summary())
roas_summary_df = (results.summary2().tables[1]) # .reset_index()
roas_summary_df = round(roas_summary_df, 3)
roas_summary_df = roas_summary_df.reset_index()
roas_summary_df.columns = ["marketing_channel", "coefficient",
                           "std_error", "t_value", "pvalue", "conf_lb", "conf_ub"]
roas_summary_df.to_excel('02_多元迴歸模型_估計的 ROAS 係數.xlsx', index=False)

# !SECTION 程式碼2
```

產出成果

02_多元迴歸模型_估計的ROAS係數.xlsx

marketing_channel	coefficient	std_error	t_value	pvalue	conf_lb	conf_ub
Facebook	4.676	0.247	18.904	0	4.188	5.164
Youtube	6.348	0.471	13.475	0	5.419	7.277
Magazine	15.807	1.351	11.697	0	13.142	18.472
const	86819.16	2724.47	31.866	0	81446.1	92192.2

Jasper詢問：「哦！這樣我基本上就可以估計出每一組行銷通路的ROAS了！不過程式碼2的產出結果中還有好幾個欄位名稱我不懂，這些對商務決策能提供更多管理意涵嗎？」

讓筆者結合統計的觀點來查看Jasper的問題，程式碼2的結果表中呈現的p值（p-value；pvalue）欄位意味有多少把握不同行銷通路可以獲得估計出來的ROAS，在統計上，我們通常會設定不超過0.05，舉例而言，假設Facebook的ROAS的p-value為

0.03，若執行Facebook的投放100次，平均會有97次的機會（ $1-0.03$ ），即97%的機會Facebook的ROAS會不等於0倍。

Jasper回饋：「哦哦！簡單來說就是在您的範例下，我有信心97次投FB的ROAS會不等於0的概念！那表中的p-value怎麼看起來都是0呢？」

原因在於，因為我們的對立假設設定為ROAS不等於0，而三組行銷通路的倍數都高於0非常多，所以三組行銷通路等於0的機率實在太低了，所以p-value在表中才會顯示為0，但這不表示p-value真的為0，只是發生ROAS等於0的機率太低，經過Python程式的四捨五入後，在表中才呈現為0。

Jasper回饋：「原來如此！就是因為ROAS不等於0的機會很高嘛！幾乎是99.99後面好幾個9的機率%，相反的ROAS等於0的機率可以說幾乎是0.000好幾個0的機率%」

Jasper接著問：「雖說p-value看似好用，但是每次測出來的ROAS總會有誤差，我是否能掌握這個誤差呢？不然我看到表中Facebook的每週平均是4.67倍，但會不會後續幾周測出來結果是0倍，結果我就賠錢了？」

從統計的觀點來說，隨機誤差（Random Error）正是統計模型百年來一直在解決的問題，而本表與隨機誤差最直接關聯的即是標準誤（Standard error；std_error）欄位。通常會在95%的信心水準下，得出係數的信賴區間，舉例而言，Facebook的平均ROAS為4.7，而其信賴區間即是 $4.7 \pm 1.96 * 0.247 = [4.2, 5.2]$ ，這代表投放Facebook廣告的平均ROAS為4.7，而真實數值則有95%的機會將會落在4.2倍到5.2倍之間，而4.2倍這個估計出來的數值通常稱為「信賴區間的上界」；5.2倍的數值則稱為「信賴區間的下界」。此外，在本表中，筆者有將ROAS信賴區間的上、下界標註為conf_lb與conf_ub欄位，代表confidence interval lower bound與confidence interval upper bound之意涵。

Jasper回饋並詢問到：「哦！太好了！這樣我就可以掌握投廣告的誤差區間了！那表中的t值是什麼啊？」

t值或稱t統計量（t-statistic；t_value）通常是來決定p-value的大小，當取絕對值後的t值越大，代表其p-value越小，即隨機誤差相對係數來說是相對較小。言下之意，即越有把握落在通路的信賴區間。從管理意涵的角度來看，若測試出來的p-value

是可以被管理者接受的（通常是0.05），若t值大於1.96或小於-1.96，其正、負也代表不同通路信在賴區間的範圍是高於或低於該對立假設，舉例來說，可見表中所有通路的t值皆為正數，意味其所有通路的信賴區間的範圍均高於對立假設為0的狀況。

Jasper回饋：「所以簡單來說，我可以先確認該通路的p-value是否小於0.05，然後，若t值為正，則不同通路的信賴區間都是大於我所設定ROAS要大於0的概念。」

Jasper繼續詢問：「整體下來很科學啊！但是有沒有更簡單讓老闆懂的方式呢？像是ROAS等呈現方式，同時也將這些統計指標放進去的那種方式。」


透過程式碼3，讀者即可快速視覺化程式碼2的表。

程式碼 3 (TODO)

```
# SECTION - 程式碼3 (Todo)
fb = results.t_test('Facebook=6')
results.t_test('Facebook=0')
fb.summary_frame()
results.summary().tables[1]
LRresult = (results.summary2().tables[1])

# !SECTION 程式碼3
```

產出成果



筆者同時將程式碼3的圖轉變為更易理解圖5，從中可知藍點即為各行銷通路的ROAS平均值，穿越藍點的橫線即為其95%信賴區間的ROAS上、下界。圖中虛線則為Jasper團隊設定ROAS至少要超過的目標倍數，在此例為0。筆者同時也將所有統計資訊羅列其中，也在圖中下方列上ROAS的管理意涵。

Jasper回饋：「太好了~！ 這樣的視覺化圖不管是統計指標還是ROAS的管理意涵都羅列的非常清楚，而且p值果然不是0，只是很小而已。」

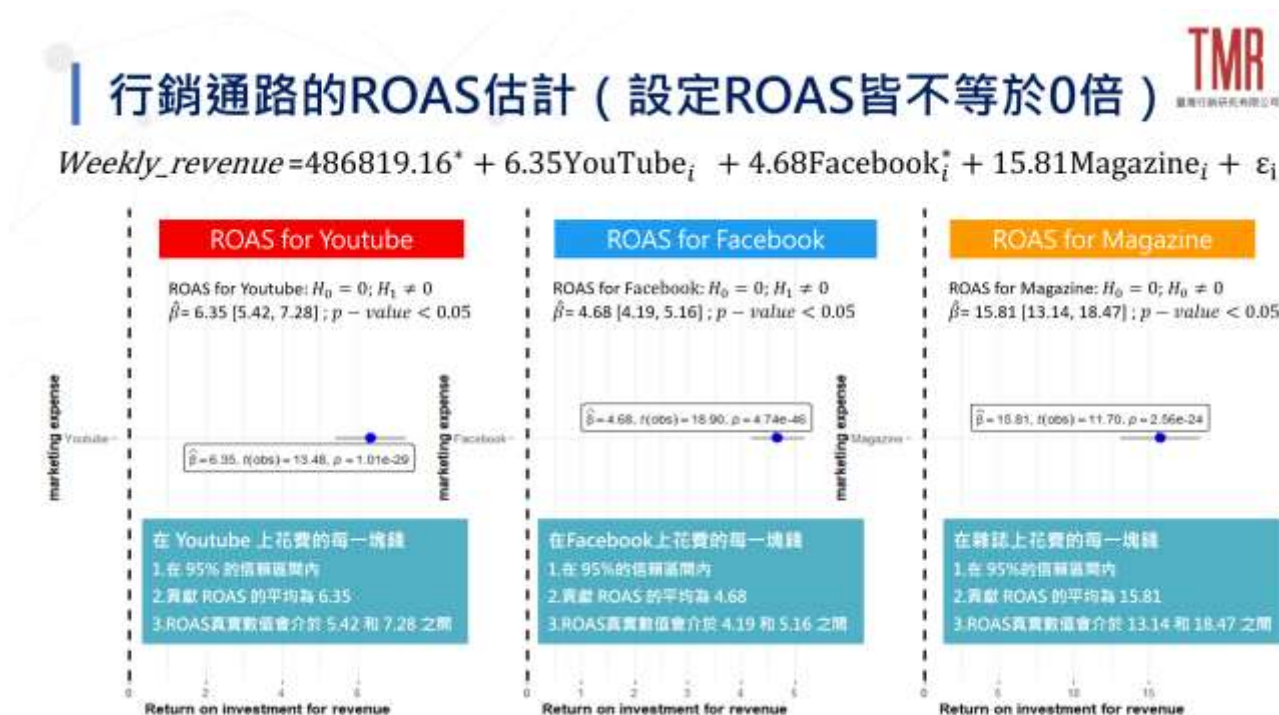


圖 5. 設定 ROAS 皆不等於 0 倍時，行銷通路的 ROAS 估計

此時，Jasper又拋出了一個關鍵性問題：「雖然能評估ROAS很讚！ 但是ROAS僅0不一定賺錢，我能不能自行設定ROAS的目標，然後來看看統計模型是否有達標呢？」

首先，讓筆者來解釋為什麼ROAS僅大於0不一定會賺錢，我們再次回到主題1的案例，並簡化成程式碼4。從程式碼4的產出成果可見就算某一行銷通路擁有1.8倍的ROAS，能創造27萬的營收，因產品成本佔營收的48%之由，導致最終該產品還是賠錢的狀態。所以此時便要請Jasper評估在ROAS能創造公司目標利潤的情況下，設定每組行銷通路的ROAS。

程式碼 4
%
SECTION - 程式碼4

```

marketing_expense = 150000
roas = 1.8
revenue = marketing_expense * roas
cost = revenue * 0.48

roas_assumed_table = pd.DataFrame({
    '項目': ['營收', '產品成本', '行銷費用', '利潤'],
    '總計金額': [revenue, cost, marketing_expense, revenue - cost -
marketing_expense],
    '備註': ['營收 = 行銷費用*1.8 倍的 ROAS', '產品成本 = 營收*48%', '行銷費用為 =
150000', '利潤 = 營收-產品成本-行銷費用']
})

roas_assumed_table.to_excel('03_ROAS 假設情境表.xlsx', index=False)

# !SECTION 程式碼4

```

產出成果

03_ROAS假設情境表.xlsx

項目	總計金額	備註
營收	270,000	營收 = 行銷費用*1.8倍的ROAS
產品成本	129,600	產品成本 = 營收*48%
行銷費用	150,000	行銷費用為 = 150000
利潤	(9,600)	利潤 = 營收-產品成本-行銷費用

Jasper回饋的預設目標如下：

1. Facebook至少可以產生至少 4 倍的 ROAS
2. YouTube至少可以產生至少 5.5 倍的 ROAS
3. Magazine至少可以產生 12 倍的 ROAS

我們將這些目標輸入程式碼5後，讀者即可快速視覺化Jasper所設定的ROAS目標。


程式碼 5 (Todo)

```
# %%
```

```
# SECTION - 程式碼5 (Todo)
fb = results.t_test('Facebook=6')
results.t_test('Facebook=0')
fb.summary_frame()
results.summary().tables[1]
LRresult = (results.summary2().tables[1])

# !SECTION 程式碼5
```

產出成果



經過整理後，我們從圖6中可得知YouTube廣告的p-value為0.07，意味會有7%的風險，ROAS無法落在5.5倍，若這樣的風險是Jasper團隊可以接受的，且有意根據未來趨勢來扶植自媒體行銷，即可持續執行YouTube的操作，並持續優化YouTube的行銷；在Facebook的部分則是會有0.7%的風險不會落在預設4倍的ROAS，但其機率相當低，則建議持續操作；在Magazine的部分則是會有0.5%的風險不會落在預設12倍的ROAS，但其機率相當低，也建議持續操作。

由此可知，Jasper所預設的目標基本上這幾則廣告均有達成自己設定的目標。

Jasper此時反饋：「雖然我心中對B商品在不同行銷通路ROAS有八九不離十的猜想，但卻是能從本分析得知我們這支商品在YouTube的經營還要更加把勁，同時在Magazine自詡真的做得不錯，其實有不少顧客向一線人員反饋很多都是看的雜誌廣告而購入B商品的。」

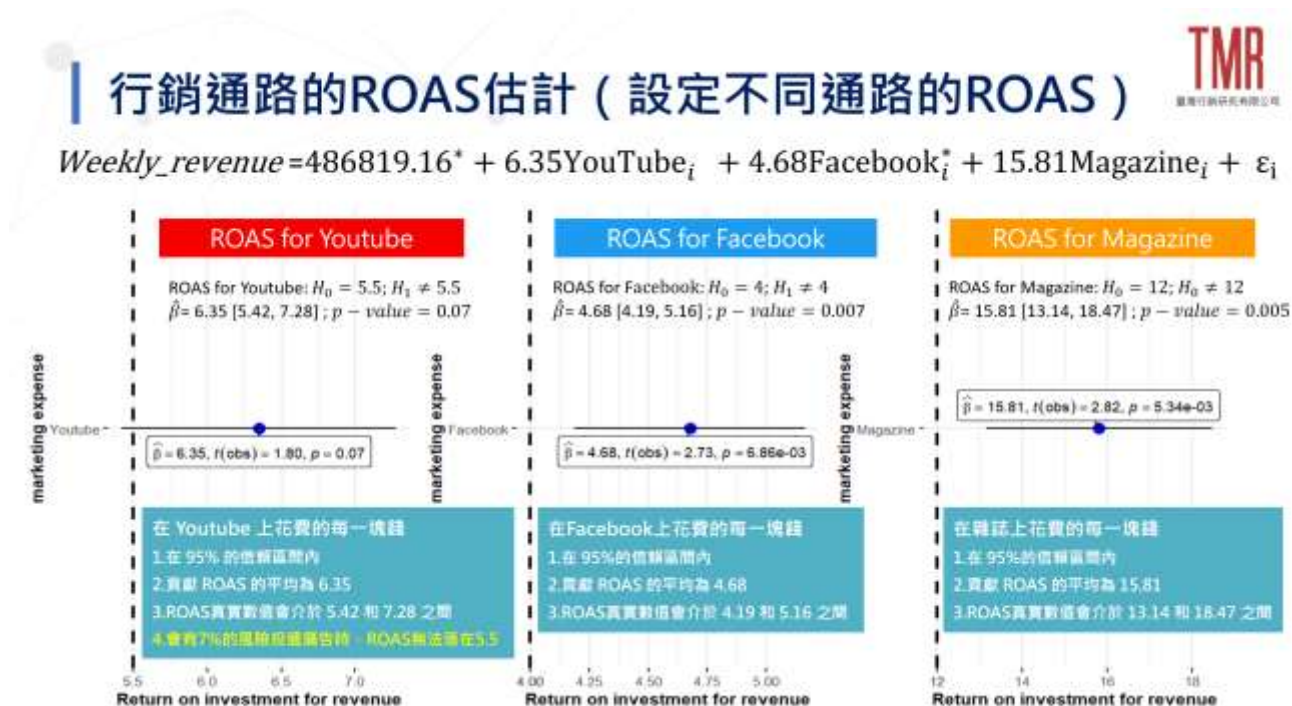


圖 6. 設定不同通路的 ROAS，行銷通路的 ROAS 估計

Jasper接著問：「既然我們現在知曉了ROAS的估計，您說也可以預測未來B商品的收益，讓算命更準嗎？哈哈！」

參、能夠透過現有通路的行銷費用資料來預測未來商品收益嗎？

既然已經建立了多元迴歸模型，即可透過程式碼6建立預測模式。讀者可在程式碼6的產出成果中見到預測週營收（綠色線）與實際週營收（黑色線）之視覺化動態比較圖，同時也附上預測區間的上界（黃色線）與下界（藍色線）。光從肉眼判讀，即可知曉預測營收與實際營收之擬合程度甚高，意味所建立之模型效果甚佳。

Jasper反饋：「看起來甚是不錯！不過有無一些指標知道具體的預測情況呢？」

```

程式碼 6

# %%
# SECTION - 程式碼6

# 訓練迴歸模型
reg_model = LinearRegression()

```



```

reg_model.fit(X, y)

# 建立預測模型
results_all, fig_all = prediction_interval(data=data,
                                           X=X, y=y,
                                           X_new=X,
                                           tuned_model=reg_model,
                                           weeks=None,
                                           output_name = '04_1_真實的週營收 vs 預測的週營收'


                                           )

# !SECTION - 程式碼6

```

產出成果

04_1_真實的週營收 vs 預測的週營收.html



透過程式碼7，即可知道不同的模型評估表現，其中最有用的莫過於「平均絕對百分比誤差（MAPE）」，其代表本多元迴歸模型的誤差率；還有「調整後R平方（Adjusted R squared；Adj_R）」，其表示模型的解釋力或稱可解釋變異量。舉例而言，我們從程式碼7的產出成果可得知其誤差率為11%，即有89%的準確率，本資料包含的通路能解釋78%的營收來源，意味尚有12%的營收尚不知道是因何而來，所

以這也建議Jasper心有餘力的狀況下，可以透過更多元的方式來蒐集對B商品影響的管道或者後續透過其他模型調整方法來增強模型的解釋力。

程式碼 7

```
# %%  
# SECTION - 程式碼 7  
  
# 模型表現評估  
perf_table = performance_metrics(X, y, results_all)  
  
# !SECTION - 程式碼 7
```

產出成果

04_2_營收分析_模型表現.xlsx

metrics	Objective_function_table
MAE	13809.02
MSE	267016780.8
RMSE	16340.65
MAPE	0.11
Adj_R	0.78

Jasper回饋：「太好了！現在我們知道ROAS的評測，也知道了模型預測效果，但是就我行銷的經驗來說，不管是投遞什麼廣告，就是我花費到一定水準的時候，成效就上不去了，不過我始終很難知道那個飽和點究竟在哪裡，也不能亂花公司的錢來測到飽和點。所以數據分析也可以解決這個問題嗎？」

肆、廣告花到多少錢就不用再打廣告了？

學者Liu與Yang在2009年於《Journal of Marketing》上有發表了一篇<Competing Loyalty Programs: Impact of Market Saturation, Market Share, and Category Expandability> (Liu & Yang, 2009)，內容提及行銷廣告或會員制服務通常都會有市場飽和效應(Market Saturation effects)，因此會讓廣告有邊際效用遞減(diminishing return)的影響，這也從Jasper證實其實務操作經驗確實如此。

那Jasper現在可以做得有兩件事情，一方面是透過廣告內容的改良來存留顧客，也就是學者Liu與Yang提到若要讓市場飽和效應遞減，則可優先改良提供的內容服

務或內容行銷手法，讓顧客可以定期感受新推出的服務，以讓顧客持續存留與消費；二方面則是數據分析的方法來改善預算分配，筆者將會善用統計機率分佈結合多元迴歸模型來協助Jasper估計不同通路行銷費用的飽和點，以此建議Jasper團隊針對每一組通路行銷費用的最適預算，而這將是筆者在本單元重點介紹的部分。

首先，筆者循序漸進，先引導讀者理解何為市場飽和效應。從最基礎的來說，市場飽和效應代表「假設我們花在廣告上的錢越多，我們的收入就越高。然而，隨著我們在廣告上的支出，收入的增長將會變差。這稱為飽和效應或收遞減效應。」

Jasper詢問：「嗯嗯！看起來很合理，這樣我也知道會多加改善內容行銷的部分，留住更多的顧客，但數據分析方面，需要用什麼統計方法來估計呢？」

筆者估計市場飽和效應的統計方法為善用「指數分佈的累積分佈函數（cumulative distribution function of exponential distribution; CDF of exponential distribution）」結合多元迴歸模型來模擬市場飽和效應，如方程式2所示。

$$F(x, \lambda) = \begin{cases} 1 - e^{-\lambda x}; & x \geq 0 \\ 0; & x < 0 \end{cases} \dots \text{方程式 2}$$



其中， x 是我們在多元迴歸模型中使用的自變量。 λ 則是一個超參數，我們可以在迴歸模型中對其進行調整，以創建在Jasper所提供的B商品之市場飽和度函數的形狀。

Jasper回饋：「哇~！ 很統計呢！ 不過我這些機率分佈啥的都還給大學老師了，哈哈！ 可以說得更淺白一些嗎？」

從圖7的左圖中，可見指數分佈的累積分佈函數視覺圖，其隨著 x 軸數值的增加，使得 y 軸數值呈現遞增式遞減，故此函數非常適合用來模擬市場飽和效應。為了讓讀者更好理解，筆者特意比擬該函數到左圖，從左圖範例可見 x 軸為預算， y 軸為飽和度，其到約莫30K的預算下，就即將達到飽和的程度，故在本範例則建議可將預算最大設定為30K即達到市場飽和，若持續提升預算，不但效益有限，且可能造成更多預算上的浪費。

市場飽和度效應函數視覺化

CDF of exponential dist.: $F(x, \lambda) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$



8

圖 7. 市場飽和度效應函數視覺化

Jasper說：「原來如此！這樣我了解了，這真是個好方法！解了我多年的疑惑！」

Jasper再次詢問：「除了您提到的市場飽和效應外，我們行銷部還有一個問題困擾著我們，就是我每發佈一則廣告，我不知道具體可以維持多久的成效？」

伍、發佈每一則廣告後，在各通路可以維持多久的成效呢？

Köhler等學者在2017年於《Journal of Marketing Research》上有發表了一篇<A Meta-Analysis of Marketing Communication Carryover Effects> (Köhler et al., 2017)，內容說明在個人化精準廣告 (targeted advertising)、人員推銷 (personal selling) 與大眾媒體廣告 (mass media advertising) 之行銷方法均有2至12月不等的影響期間，而行銷活動影響消費者的期間稱之為「遞延效應 (Carryover Effects)」，而這也是Jasper為什麼無法很清楚判別什麼時候停止打廣告的困擾點。

同樣的，Jasper一樣可以做兩件事情，其一為B商品「精準行銷」的建構，Köhler等學者建議廣告可以走向「個人化精準廣告」或「人員推銷」來執行，研究表明其行銷遞延效應的時間通常較大眾媒體來得更長，所以這也意味著Jasper團隊在B商品的行銷上，除了一般的數位與實體廣告投放外，更應該還要注重在如主題一的CRM資料蒐集與精準行銷，還有請實體通路高業績人員的向其他業務人員做好銷售培訓。其二為善用數據分析方法找出三組行銷通路的遞延效應，以利多元迴歸模型判別最適預算。

首先，筆者一樣循序漸進，先引導讀者理解何為遞延效應。從最基礎的來說，遞延效應代表「我們在廣告上花錢，用戶往往不會立即購買我們的產品，而是在幾週之後才有可能購買。因為用戶要仔細考慮它或將它與其他公司的同類產品進行比較，這就稱為遞延效應。」

Jasper詢問：「但數據分析方面，需要用什麼統計方法來估計呢？」

筆者使用的是卷積法（convolution method）來量化評估遞延效應，在圖8中，可了解具體做法為決定移動框格（Sliding window）的數量以及決定框格裡面的權重（weights），在本案則分別代表「行銷影響用戶的週數」及「行銷效果影響用戶的比例」。

接著，每移動一次框格，就將原始Data中的預算與框格權重相乘，就可以得到遞延效應的確切量化結果，舉圖X釋例而言，目前Data第一週的預算分佈費用為16，那遞延效應即為16（Result）。




圖 8. 遞延效應在第一週的資料示意圖

接續上例至圖9，當Data第二週的預算分佈費用為0，但是因遞延效應之影響，則 16×0.5 的框格權重，則第二週的遞延效應即為8。這即模擬第一週投入16的預算費用還有一半的行銷效果存在顧客的心中，而隨著時間流淌，對消費者的行銷效果則會越弱。

(16, 8, 4, 0, 0, 4, 10, 5, 2, 0).

Sliding Window

0.25	0.5	1
------	-----	---

Data

16	0	0	0	0	4	8	0	0	0
----	---	---	---	---	---	---	---	---	---

Result

16	8								
----	---	--	--	--	--	--	--	--	--

圖 9. 遞延效應在第二週的資料示意圖

接續上例至圖10，當Data第三週的預算分佈費用為0，但是因遞延效應之影響，則 16×0.25 的框格權重，則第三週的遞延效應即為4。這即模擬第一週投入16的預算費用到了第三週後，還有1/4的行銷效果存在顧客的心中，而隨著時間流淌，到了第四週就不再有效用，如圖11所示。

(16, 8, 4, 0, 0, 4, 10, 5, 2, 0).

Sliding Window

0.25	0.5	1
------	-----	---

Data

16	0	0	0	0	4	8	0	0	0
----	---	---	---	---	---	---	---	---	---

Result

16	8	4							
----	---	---	--	--	--	--	--	--	--

圖 10. 遞延效應在第三週的資料示意圖

(16, 8, 4, 0, 0, 4, 10, 5, 2, 0).

Sliding Window

0.25	0.5	1
------	-----	---

Data

16	0	0	0	0	4	8	0	0	0
----	---	---	---	---	---	---	---	---	---

Result

16	8	4	0						
----	---	---	---	--	--	--	--	--	--

圖 11. 遞延效應在第四週的資料示意圖

按照這種方式，以此類推，最終可獲得圖12的遞延效應量化結果。所以從此簡例便知其遞延效應為3週。同樣的，遞延效應可結合迴歸模型並對其「移動框格」與「框格權重」進行調整。




圖 12. 遞延效應資料示意圖

Jasper心滿意足的回饋：「原來如此~！ 這樣就好辦了！多年疑惑原來皆可用數據分析量化出來！真是太厲害了！」

但接著Jasper又持續提問：「既然我們現在有了遞延效應與市場飽和效應可以結合您所說的多元迴歸模型，那實際上該如何做呢？」

陸、遞延效應與市場飽和效應如何結合到多元迴歸模型？

請各位讀者注意，本節筆者接下來會使用較多的統計數學式，若不習慣閱讀統計模型或數學式的讀者，可以直接往後翻到「一起來找出遞延效應與市場飽和效應！」的小節，並直接用筆者寫好的Python程式碼一起來實作。

Danaher等學者在2008年於《Journal of Marketing Research》上有發表了一篇<The Effect of Competitive Advertising Interference on Sales for Packaged Goods> (Danaher et al., 2008)，內容首次說明「遞延效應」與「市場飽和效應」如何相互結合，並首次探討對銷售（sales）的影響，並得出其對銷售之間是有明顯的效用。筆者善用本文獻之概念並對其改良，將「遞延效應」與「市場飽和效應」，以學者Akiba在2019年提出的機器學習高效修剪策略（efficient pruning strategy）(Akiba et al., 2019)為主的Optuna超參數（hyperparameter）調整方法來自動調整諸如： ϕ 、 η 、 λ 等

原須人工決定的超參數，如此筆者便能根據不同個案以模型推導過往學者較難確切從「遞延效應」與「市場飽和效應」中知曉的相關超參數。接續的段落將闡述主要的迴歸模型與需要調整之超參數。

要將遞延效應與市場飽和效應如何結合到多元迴歸模型，會需要先建立本案所需的迴歸式，如方程式3所示。

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon_t$$

$$\Rightarrow \begin{cases} x_1 = YouTube \\ x_2 = Facebook \dots \text{方程式 3} \\ x_3 = Magazine \end{cases}$$

接著，將遞延效用結合到迴歸式中，如方程式4所示。

$$y_t = \beta_0 + \beta_1(x_{1t} + \phi_1 \eta_{1t-1}) + \beta_2(x_{2t} + \phi_2 \eta_{2t-1}) + \beta_3(x_{3t} + \phi_3 \eta_{3t-1}) + \varepsilon_t \dots \text{方程式 4}$$

其中 x_t 、 ϕ 與 η 問遞延效應的超參數，分別代表時間、移動框格與框格權重

- ◆ x_t ：代表每週不同時間下(t)，各行銷通路廣告曝光的費用
- ◆ ϕ ：代表移動框格，在本案為「行銷影響用戶的週數」
- ◆ η ：代表框格權重的強度或稱遞延效應的強度，介於 0 和 1 之間，在本案為「行銷效果影響用戶的比例」

再來將方程式4與市場飽和效應的方程式5相互結合。

$$F(x, \lambda) = \begin{cases} 1 - e^{-\lambda x}; & x \geq 0 \\ 0; & x < 0 \end{cases} \text{ to } x_t \dots \text{方程式 5}$$

即轉變為方程式6。

$$y_t = \beta_0 + \beta_1[(1 - e^{-\lambda x_{1t}}) + \phi_1 \eta_{1t-1}] + \hat{\beta}_2[(1 - e^{-\lambda x_{2t}}) + \phi_2 \eta_{2t-1}] + \hat{\beta}_3[(1 - e^{-\lambda x_{3t}}) + \phi_3 \eta_{3t-1}] + \varepsilon_t \dots \text{方程式 6}$$

然後將方程式6的 $(1 - e^{-\lambda x_{st}}) + \phi_s \eta_{st-1}$ 以 τ_s 替代，如方程式7所示。

$$\Rightarrow \tau_s = (1 - e^{-\lambda x_{st}}) + \phi_s \eta_{st-1} \dots \text{方程式 7}$$

其中， x 是在多元迴歸模型中使用的自變量，在本案即是三組行銷通路。 λ 則是一個超參數，以用來決定B商品之市場飽和度函數的形狀。

最後，將方程式7的 τ_s 套入方程式，即可得方程式8。

$$\Rightarrow y_t = \beta_0 + \beta_1\tau_1 + \beta_2\tau_2 + \beta_3\tau_3 + \varepsilon_t \dots \text{方程式 8}$$

如此一來，便完成了多元迴歸模型與遞延效應與市場飽和效應的結合。在下一節，筆者將帶領讀者使用方程式8來實作找出遞延效應與市場飽和效應，並闡述其行銷之管理意涵。

柒、一起來找出遞延效應與市場飽和效應！

本節筆者將實作並找出Jasper本案的遞延效應與市場飽和效應，並闡述其行銷之管理意涵。筆者將遞延效應與市場飽和效應在程式碼8中融合到自創套件的函數「train_marketing_carryover_saturation」中與迴歸模型一同訓練，我們且稱該迴歸模型為「行銷迴歸模型」。請讀者特別注意，在行銷迴歸模型訓練的過程中，同時也會協助找尋遞延效應與市場飽和效應的最佳參數，如：移動框格、框格權重等，故會出現程式碼8產出成果中的「行銷迴歸模型訓練過程真實狀況」並且會持續以極快的速度生成出來，所以並不是電腦壞掉了，只是模型正在訓練中。

訓練完畢後，會印出best_param，就可看到不同行銷通路廣告的超參數已經被決定出來，舉Facebook通路來說，稱遞延效應的強度（carryover_strength； η ）即為34%，即原廣告效益若無100%，後續則是以34%的效益傳遞並逐步遞減；遞延效應的移動框格（carryover_window； ϕ ）即為7週；飽和效應中決定市場飽和度函數形狀的參數為0.000107（saturation_exponent； λ ）。其他通路之效應也以此類推。

程式碼 8

```
# %%  
# SECTION - 程式碼8  
  
# 將carryover 與saturation 融合到迴歸模型，並訓練之  
tuned_model, best_param = train_marketing_carryover_saturation(X, y,  
n_trials=1000)  
  
# 秀出最好的參數組合  
print(f"best_param\n: {best_param}")  
# !SECTION - 程式碼8
```

產出成果

行銷迴歸模型訓練過程真實狀況

```

# 33
# SECTION - 程式碼8

# 將carryover與saturation組合到迴歸模型，並訓練之
tuned_model, best_param = train_marketing_carryover_saturation(x, y,

# 找出最好的參數組合
print("best_param: ", best_param))

# 33c100 - 程式碼8

[I 2023-01-20 00:12:42.100] Trial 15 finished with value: 0.09323300537710174 and
parameters: {'adstock_facebook_pipe_carryover_strength': 0.515370898748483,
'adstock_facebook_pipe_carryover_window': 4,
'adstock_facebook_pipe_saturation_exponent': 0.00792013563130318,
'adstock_youtube_pipe_carryover_strength': 0.5626904643953704,
'adstock_youtube_pipe_carryover_window': 5,
'adstock_youtube_pipe_saturation_exponent': 0.003026153733088266,
'adstock_magazine_pipe_carryover_strength': 0.7911137243092776,
'adstock_magazine_pipe_carryover_window': 8,
'adstock_magazine_pipe_saturation_exponent': 0.0011886637001030010}. Best is
trial 15 with value: 0.6450005772010935.

```

best_param

	best_param		
:		para	effect
0	adstock__Facebook_pipe__carryover__strength	0.339344	
1	adstock__Facebook_pipe__carryover__window	7.000000	
2	adstock__Facebook_pipe__saturation__exponent	0.000107	
3	adstock__Youtube_pipe__carryover__strength	0.006373	
4	adstock__Youtube_pipe__carryover__window	4.000000	
5	adstock__Youtube_pipe__saturation__exponent	0.009730	
6	adstock__Magazine_pipe__carryover__strength	0.003113	
7	adstock__Magazine_pipe__carryover__window	0.000000	
8	adstock__Magazine_pipe__saturation__exponent	0.000014	

tuned_model.dat



tuned_model.dat

讀者可以特別注意的是，程式碼8同時也會產出一個程式碼檔案在資料夾中，名為tuned_model.dat，以利後續讀者重開Python IDE編輯器時，不用在重新訓練模型一次，則可以直接以程式碼9直接載入（load）資料夾中的模型，以節省讀者的時間，以利後續操作。

程式碼 9

```

# %%
# SECTION - 程式碼9

# ----- Load tuned marketing mix model ----- #

```



```
tuned_model, best_param = load_tuned_model(tune_model_path="tuned_model.dat")

print(f"best_param\n: {best_param}")
print(f"best_param\n: {tuned_model}")

# !SECTION - 程式碼9
```

產出成果

```
✓ print(f"best_param\n: {best_param}") ...
... best_param
:
      para    effect
0  adstock__Facebook_pipe__carryover__strength  0.339344
1    adstock__Facebook_pipe__carryover__window  7.000000
2  adstock__Facebook_pipe__saturation__exponent  0.000107
3    adstock__Youtube_pipe__carryover__strength  0.006373
4    adstock__Youtube_pipe__carryover__window  4.000000
5  adstock__Youtube_pipe__saturation__exponent  0.009730
6  adstock__Magazine_pipe__carryover__strength  0.003113
7    adstock__Magazine_pipe__carryover__window  0.000000
8  adstock__Magazine_pipe__saturation__exponent  0.000014

✓ print(f"best_param\n: {tuned_model}") ...
... best_param
: OptunaSearchCV(cv=TimeSeriesSplit(gap=0, max_train_size=None,
n_splits=5, test_size=None),
                estimator=Pipeline(steps=[('adstock',

ColumnTransformer(transformers=[('Facebook_pipe',

Pipeline(steps=[('carryover',

ExponentialCarryover()),

('saturation',
```

Jasper回饋：「哈哈，我都聽傻了，也感覺自己都快成半個資料科學家了，也真的很厲害！不過，我很好奇最後的成果是？」

讓筆者開始帶領各位讀者用Python動態視覺化三組行銷通路，後續再佐以相關圖表來闡述視覺化之管理意涵。

由程式碼10即可動態視覺化知Facebook通路的遞延效應與飽和效應，並產出00_【Facebook】 - 廣告延遲效用圖.html、01_【Facebook】 - 廣告飽和效用圖.html、02_【Facebook】 - 預算與毛利分析圖.html。

特別需要請讀者注意的是「01_【Facebook】 - 廣告飽和效用圖.html」即呈現了之前提過的指數分佈之形狀，可見目前最大投遞預算(max budget so far)為13,901元，其飽和度(saturation point)為77.37%，但經機器學習之運算，則建議可以將預算提升到16,582元，其飽和度為83%，同時也可以得知其營收狀況。

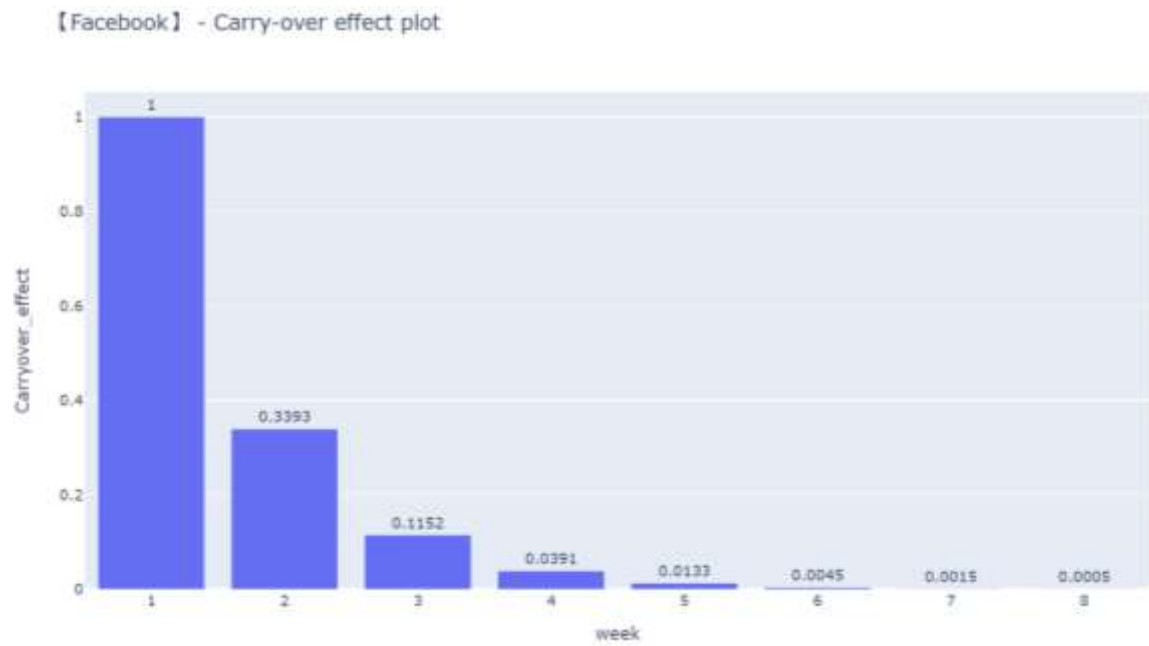
而「02_【Facebook】 - 預算與毛利分析圖.html」則是接續「01_【Facebook】 - 廣告飽和效用圖.html」之延伸，筆者將其y軸置換成毛利(營收-行銷通路費用)，如此便可找到行銷費用對應的最高毛利所在，故本例之Facebook通路之預期最高毛利(Expected max margin)為137,006元，且對應值飽和度同樣為83%。往後我們將以預算與毛利分析圖配合「00_【Facebook】 - 廣告延遲效用圖.html」來闡述相關之管理意涵。

程式碼 10

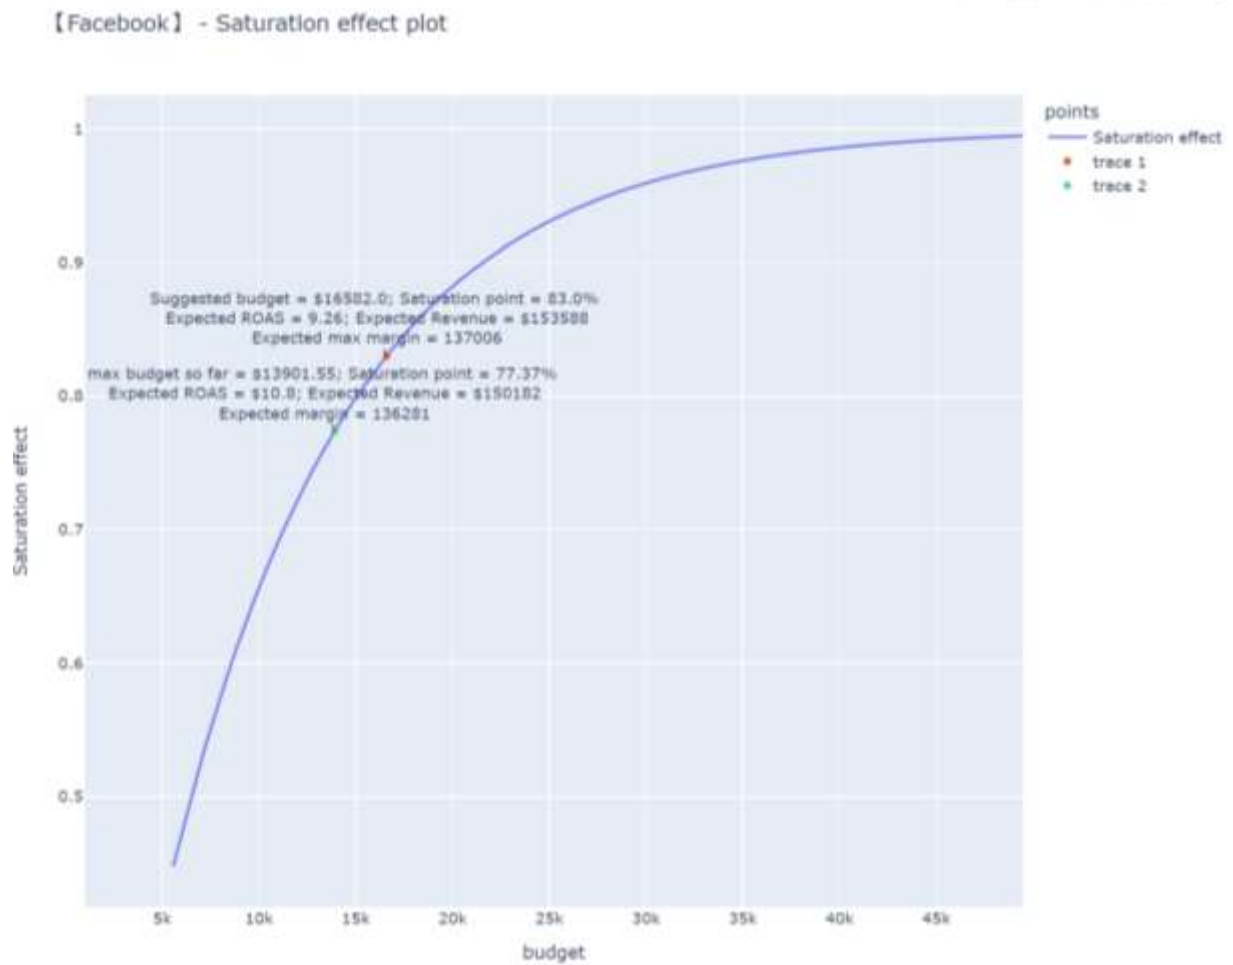
```
# %%  
# SECTION - 程式碼10  
  
# Facebook 的遞延效應與飽和效應  
fb_prop_budget, Carryover_plot, saturation_fig, budget_margin_plot = effect_plot(  
    X=X, variable_name=(variable_name := 'Facebook'),  
    tuned_model=tuned_model, best_param=best_param, only_prop_budget=False)  
  
# !SECTION - 程式碼10
```

產出成果

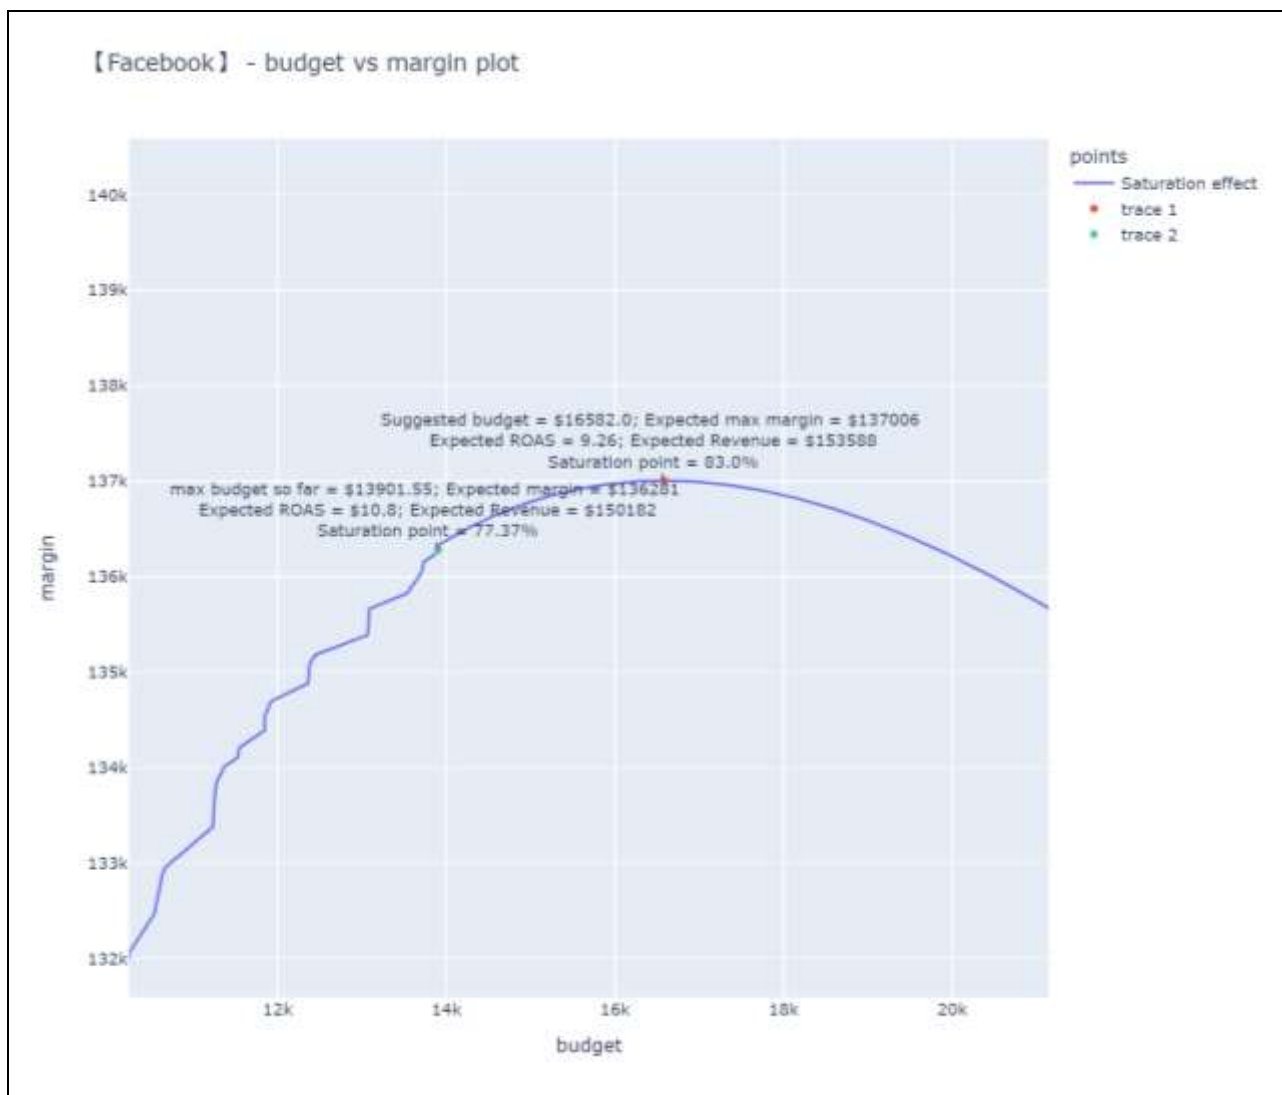
00_【Facebook】 - 廣告延遲效用圖.html



01_【Facebook】 - 廣告飽和效用圖.html



02_【Facebook】 - 預算與毛利分析圖.html



由程式碼11即可動態視覺化知YouTube通路的遞延效應與飽和效應，並產出00_【Youtube】 - 廣告遞延效用圖.html、01_【Youtube】 - 廣告飽和效用圖.html、02_【Youtube】 - 預算與毛利分析圖.html。

程式碼 11


```
# %%
# SECTION - 程式碼11
# Youtube 的遞延效應與飽和效應
yt_prop_budget, Carryover_plot, saturation_fig, budget_margin_plot = effect_plot(
    X=X, variable_name=(variable_name := 'Youtube'),
    tuned_model=tuned_model, best_param=best_param, only_prop_budget=False)

# !SECTION - 程式碼11
```

產出成果

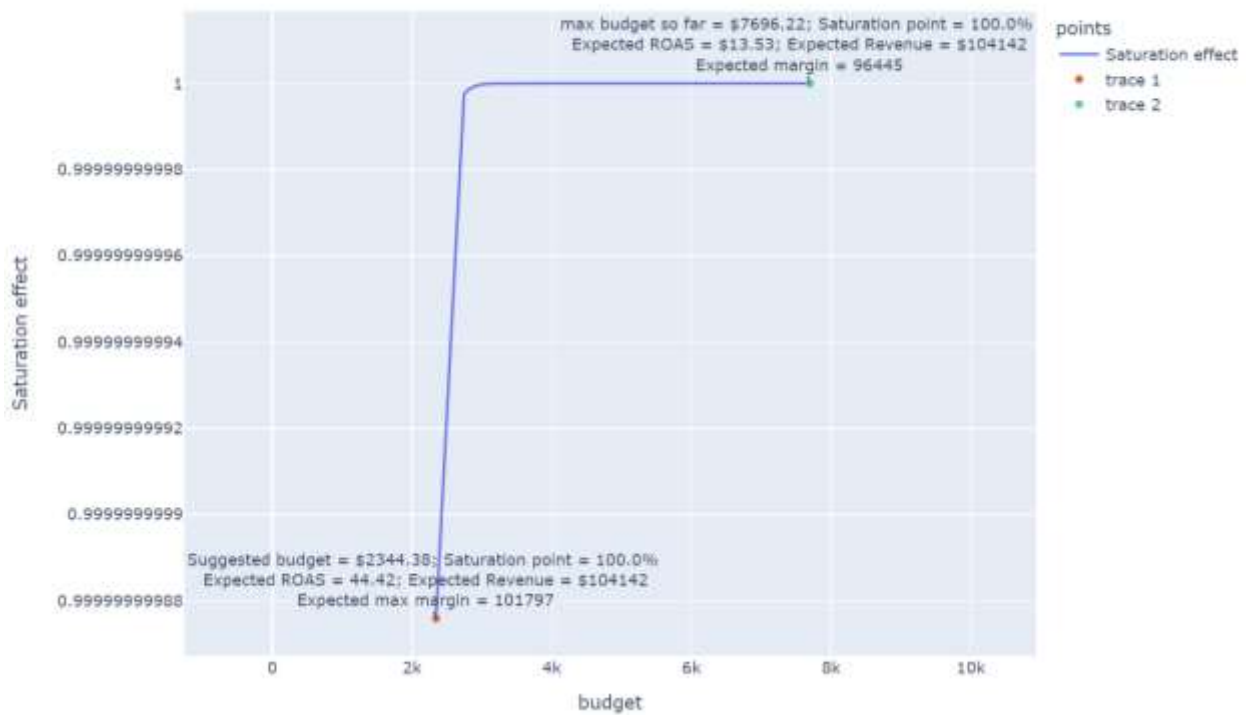
00_【Youtube】 - 廣告遞延效用圖.html

【Youtube】 - Carry-over effect plot




01_【Youtube】 - 廣告飽和效用圖.html

【Youtube】 - Saturation effect plot



02_【Youtube】 - 預算與毛利分析圖.html

【Youtube】 - budget vs margin plot



由程式碼12即可動態視覺化知Magazine通路的遞延效應與飽和效應，並產出00_【Magazine】 - 廣告遞延效用圖.html、01_【Magazine】 - 廣告飽和效用圖.html、02_【Magazine】 - 預算與毛利分析圖.html。

程式碼 12


```
# %%
# SECTION - 程式碼12
# Magazine 的遞延效應與飽和效應
mg_prop_budget, Carryover_plot, saturation_fig, budget_margin_plot = effect_plot(
    X=X, variable_name=(variable_name := 'Magazine'),
    tuned_model=tuned_model, best_param=best_param, only_prop_budget=False)

# !SECTION - 程式碼12
```

產出成果

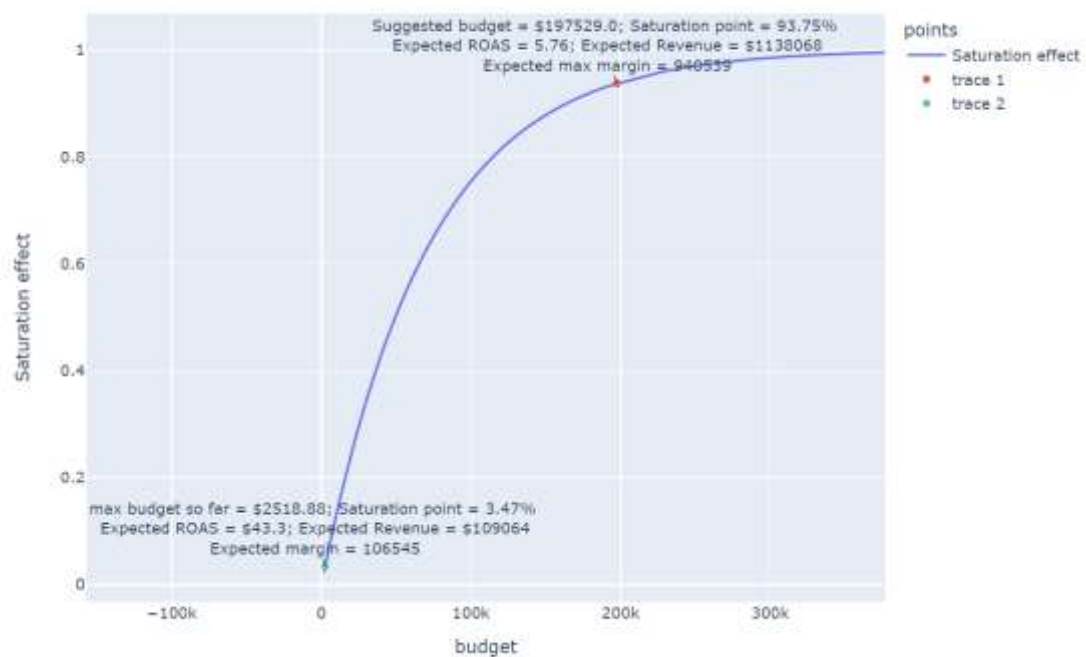
00_【Magazine】 - 廣告遞延效用圖.html

【Magazine】 - Carry-over effect plot

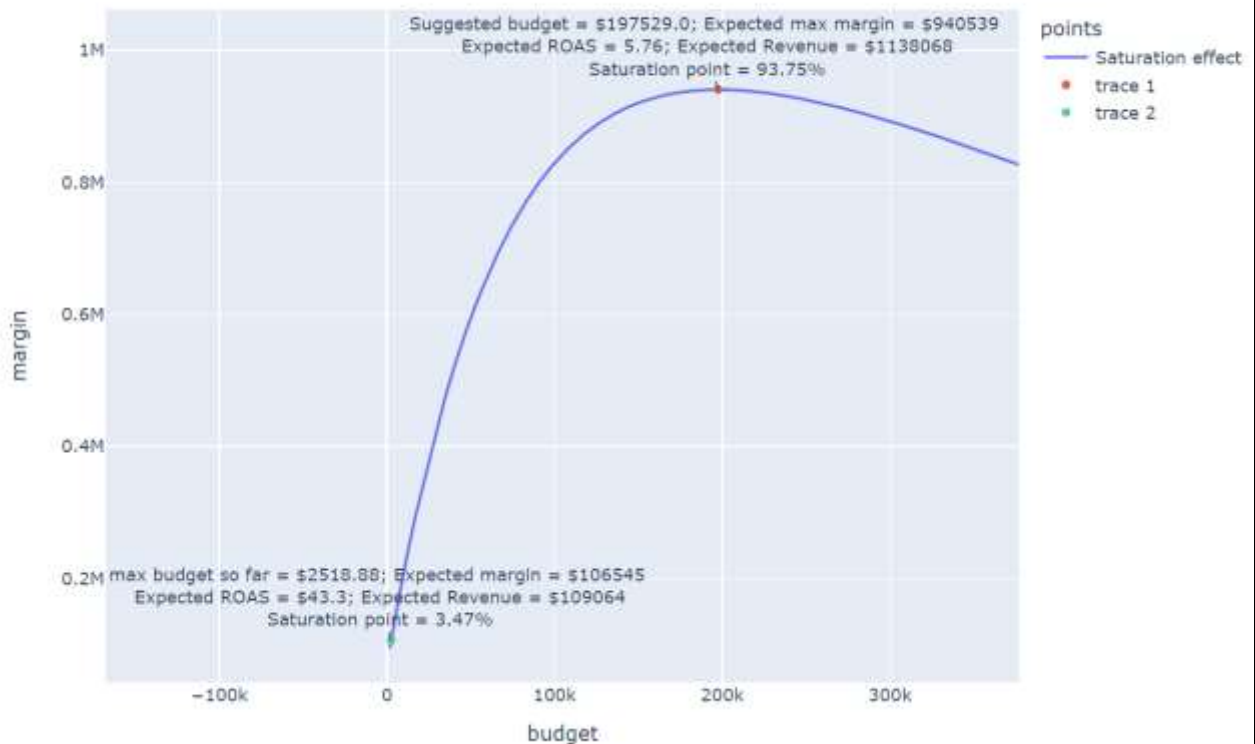


01_【Magazine】 - 廣告飽和效用圖.html

【Magazine】 - Saturation effect plot




【Magazine】 - budget vs margin plot




在動態視覺化的遞延效應與市場飽和效應之管理意涵層面。首先來看到代表 Facebook行銷通路管理意涵的圖 13，從右圖中，Jasper 可以為 YouTube 分配 \$16,582 元的建議預算，在左圖中，這行銷效用至少會影響 8 週並達到 83%。此外，它每週可能會產出 ROAS 9.26 倍的效果及 153,588 元的毛利。最後，建議分配超過過往所用過的 13,901 元的預算，因為其毛利還沒有到最大化。

Facebook 行銷通路的管理意涵

Facebook - Carry-over effect plot



Facebook - budget vs margin plot




1. Jasper 可以為 Facebook 分配 \$16,582 元的建議預算，進行銷效用至少會影響 8 週並達到 83%。
2. 它每週可能會產出 ROAS 9.26 倍的效果及 153,588 元的毛利。
3. 建議分配超過過往所用過的 13,901 元的預算，因為其毛利還沒有到最大化。

圖 13. Facebook 行銷通路的管理意涵


再來看到代表 YouTube 行銷通路管理意涵的圖 14，從右圖可知 Jasper 可以為 YouTube 分配 2,344 元的建議預算，在左圖中，其行銷效用至少會影響 2 週。此外，每週可能還會產出 ROAS 44.42 倍的效果及 101,797 元的毛利。最後，建議不要分配過往超過 7,696 元的預算，因為其毛利正在逐步遞減且也已經達到 100% 的飽和度。

YouTube 行銷通路的管理意涵

YouTube - Carry-over effect plot



YouTube - budget vs margin plot



1. Jasper 可以為 YouTube 分配 2,344 元的建議預算，進行銷效用至少會影響 2 週，並達到 100% 的飽和度。
2. 它每週可能會產出 ROAS 44.42 倍的效果及 101,797 元的毛利。
3. 建議不要分配過往超過 7,696 元的預算，因為其毛利正在逐步遞減，且也已經達到 100% 的飽和度。

圖 14. YouTube 行銷通路的管理意涵

最後看到代表 Magazine 行銷通路管理意涵的圖 15，從右圖可知 Jasper 可以為 Magazine 分配 197,529 元的建議預算，在左圖中，這行銷效用至少會影響 1 週，並達到 93.75% 的飽和度。它每週可能會產出 ROAS 5.76 倍的效果，雖然 ROAS 不盡之前理想，但若依毛利來看，則建議加高投入金額，則有機會獲得 940,539 元之毛利。建議不要僅分配過往少於 2,518 元的預算，雖然其 ROAS 達到 43，但因毛利尚未最大化，且僅達到 3.47% 的飽和度，所以建議要提高金額，加大力度。

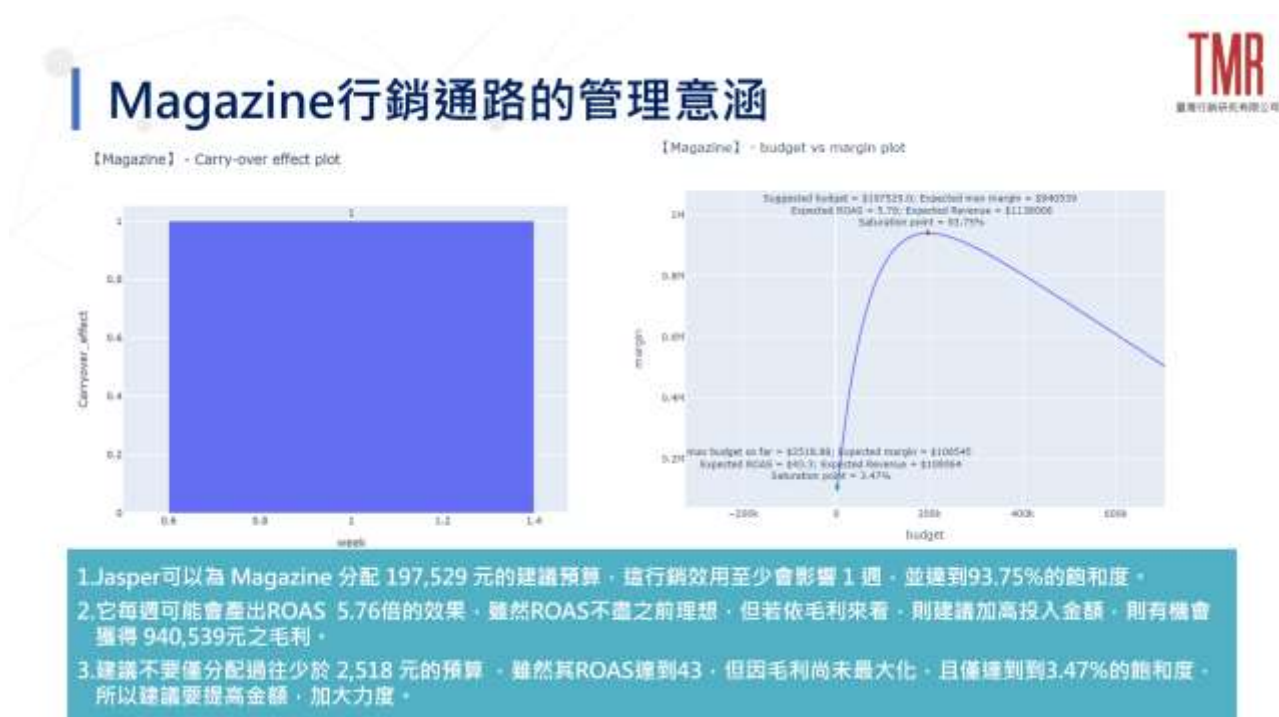


圖 15. Magazine 行銷通路的管理意涵

Jasper 回饋：「關於 Magazine 行銷建議這點很重要，一直以來這種實體廣告時常被行銷部拿來檢討，一直說現在是自媒體的時代，還在 C、D、E 等通路打什麼 Magazine 廣告（因通路敏感之故，在此 C、D、E 代表雜誌所打的通路），不僅很難追蹤成效，效果通常也僅有短期的記憶效果。不過透過本次的分析，消費者的記憶點雖然只有 1 週左右，但確實可見 Magazine 對我們 B 商品的多數受眾是有極大的效果的。尤其我們 B 商品比較偏向使用期較長且價格高的狀況，數位行銷讓消費者來持續的效益確實有限。」

Jasper 持續滔滔不絕的回饋：「所以綜整前述分析，行銷部如何將 Magazine 的廣告能做得更加具衝動性消費，且有機會配合期刊建議能達到一對一人員銷售的聯絡方式，最後能優先導引消費者到我們的 Facebook，再來是 YouTube，然後可以透

過個人化精準廣告來推播相關訊息給他們，予以誘因，再請他們推薦給親朋好友，以增益銷售的可能性！」

Jasper最後問：「向您學了這麼多，先多問這個改良過的行銷迴歸模型預測表現為何呢？」

捌、融合遞延效應與市場飽和效應的行銷迴歸模型預測效果如何？


到底融合了遞延效應與市場飽和效應的行銷迴歸模型表現有比之前的迴歸模型好嗎？透過程式碼13我們一樣同程式碼6的產出成果，得到了預測的週營收與實際狀況以及行銷迴歸模型預測效果與真實狀況表現評估表。

程式碼 13

```
# %%  
# SECTION - 程式碼13  
  
# 新行銷模型的預測表現  
results_all, fig_all = prediction_interval(data=data,  
                                           X=X, y=y,  
                                           X_new=X,  
                                           tuned_model=tuned_model,  
                                           weeks=None,  
                                           output_name = '05_1_營收分析_行銷迴歸模型  
預測效果與真實狀況',  
                                           )  
  
# performance_metrics in practice  
perf_table = performance_metrics(X, y, results_all,  
                                  output_name = '05_2_營收分析_行銷迴歸模型預測效果與  
真實狀況表現評估表')  
  
# !SECTION - 程式碼13
```

產出成果

05_1_營收分析_行銷迴歸模型預測效果與真實狀況.html



05_2_營收分析_行銷迴歸模型預測效果與真實狀況表現評估表.xlsx

metrics	Objective_function_table
MAE	6789.47
MSE	71009730.46
RMSE	8426.73
MAPE	0.05
Adj_R	0.94

讀者可以先用肉眼細細比較圖16，哪一個是之前建構的「多元迴歸模型」？哪一個是現在最新的「行銷迴歸模型」？

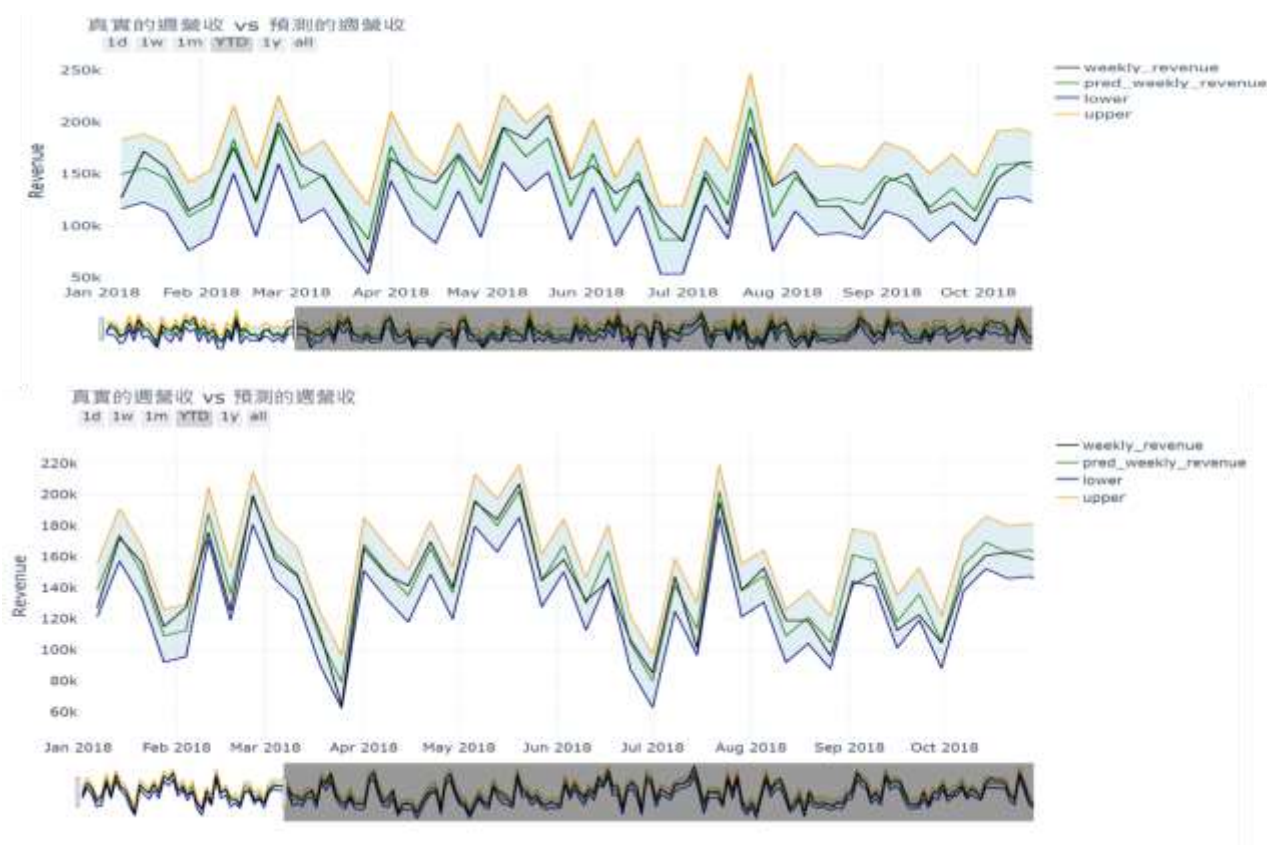


圖 16. 多元迴歸模型與新創的行銷迴歸模型表現比較圖

想必讀者透過與預測營收線（綠色線）與實際營收線（黑色線），還有預測區間的上、下界的寬窄，馬上就可以知道圖16的上圖為之前的迴歸模型；下圖為新創的行銷迴歸模型。

Jasper回問：「看起來好像是，有跟之前一樣模型比較表可以對照嗎？」

在圖17中，可見左圖，原先的多元迴歸模型誤差率為11%，即有89%的準確率，同時本資料包含的通路能解釋78%的營收來源；反觀右圖，新創的行銷迴歸模型誤差率為5%，即有95%的準確率，同時本資料包含的通路加上「遞延效應與市場飽和效應」能解釋94%的營收來源，這代表新模型不但誤差率低，且有容納「遞延效應與市場飽和效應」兩大效應是更加解釋且模擬了消費者在行銷廣告思維模式。

多元迴歸模型結果	
metrics	Objective_function_table
MAE	13809.02
MSE	267016780.8
RMSE	16340.65
MAPE	0.11
Adj_R	0.78

行銷迴歸模型結果	
metrics	Objective_function_table
MAE	6789.47
MSE	71009730.46
RMSE	8426.73
MAPE	0.05
Adj_R	0.94

圖 17. 多元迴歸模型與新創的行銷迴歸模型表現比較表

Jasper回饋：「感謝您！這樣我實務與統計上的問題都解決了！ 開始行動去！」

玖、後記：低程式碼決策工具(Low-code app)在自動化預算策略的應用

當然本案沒有因此結束，後續Jasper異想天開詢問：「上次效果不錯，有改善不少！現在既然有這些相關的分析成果，那是否能自動化分配不同廣告預算到不同通路？ 然後也看看自動化的預算策略是否能夠超越人工預算分配策略？ 這樣以後先給機器跑，我就甬這麼累啦~！」

這是完全沒有問題的！筆者團隊善用Python技術結合網頁技術，完成了一組Low-code app網頁應用，讓Jasper團隊往後只要將圖18顯示的行銷通路費用與週營收表來用如圖19與20的拖拉方式（drag and drop）放入到App裡面，即可開始執行分析

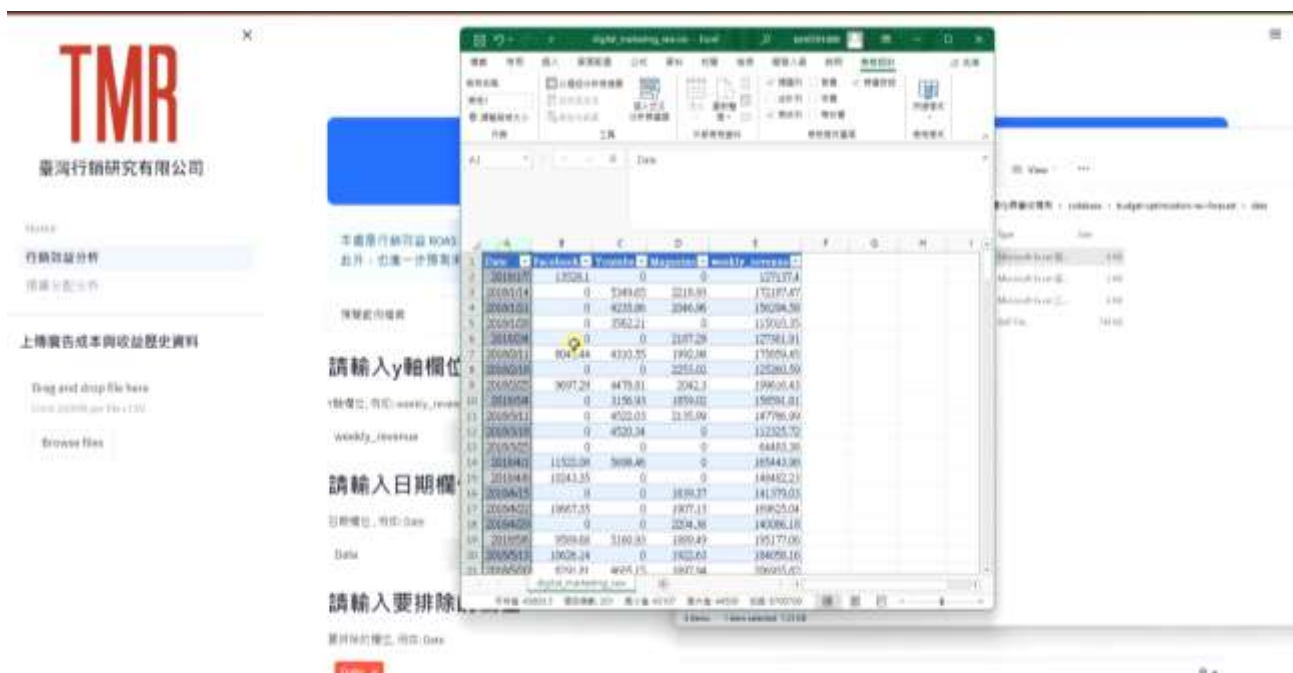


圖 18. 行銷預算與營收表示意

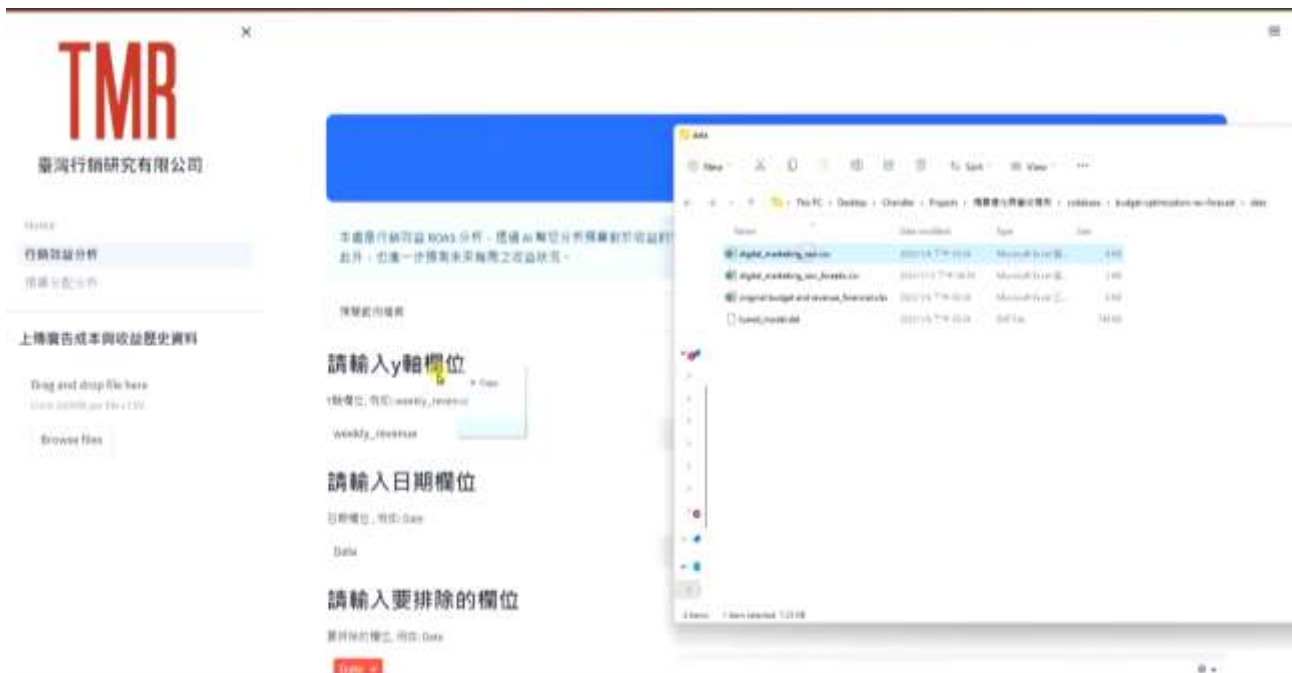


圖 19. 拖拉 (drag and drop) 行銷預算與營收表進App即可開始分析



圖 20. 拖拉 (drag and drop) 行銷預算與營收表進App即可開始分析

檔案上傳成功伊始，機會出現圖21的模樣，讓Jasper可以多加檢視資料表的正確性。



圖 21. 分析前的輸入資料檢視

再來可以自行訂定相關需求欄位與需要排除的欄位，如圖22與23所示。



圖 22. 自訂目標變數



圖 23. 自訂排除的欄位

為了更確保Jasper提供的資料建模前之正確性與整潔性，筆者即會產出特徵變數（預測變數）與目標變數（預測目標）表，提供Jasper再次確認要放入迴歸模型變數是否正確，如圖24所示。



圖 24. 再次檢視預測變數與預測目標變數

令Jasper引頸期盼的部分就來了，點擊如圖25的「行銷效益分析」按鈕後，即會產出圖26的Facebook最適預算。



圖 25. 點擊「行銷效益分析」按鈕，開始機器學習分析

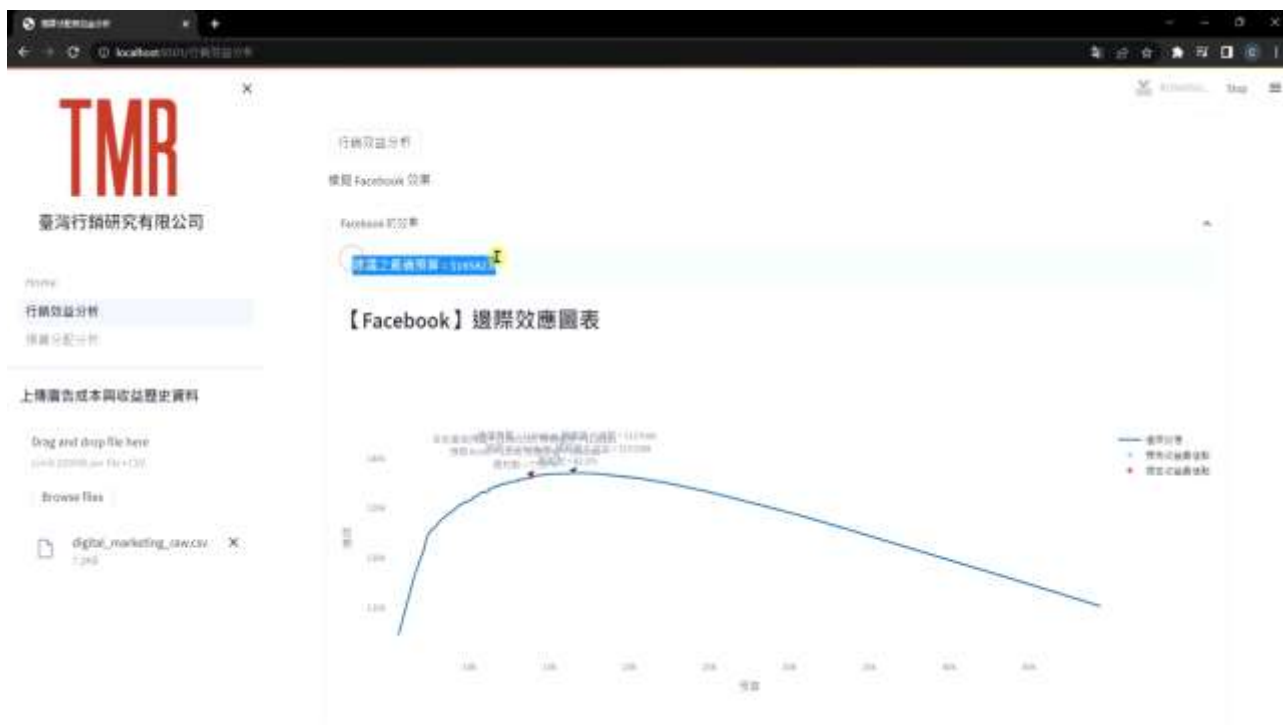


圖 26. Facebook最適預算圖表

同時也能縮放市場飽和效應圖表，如圖27所示。

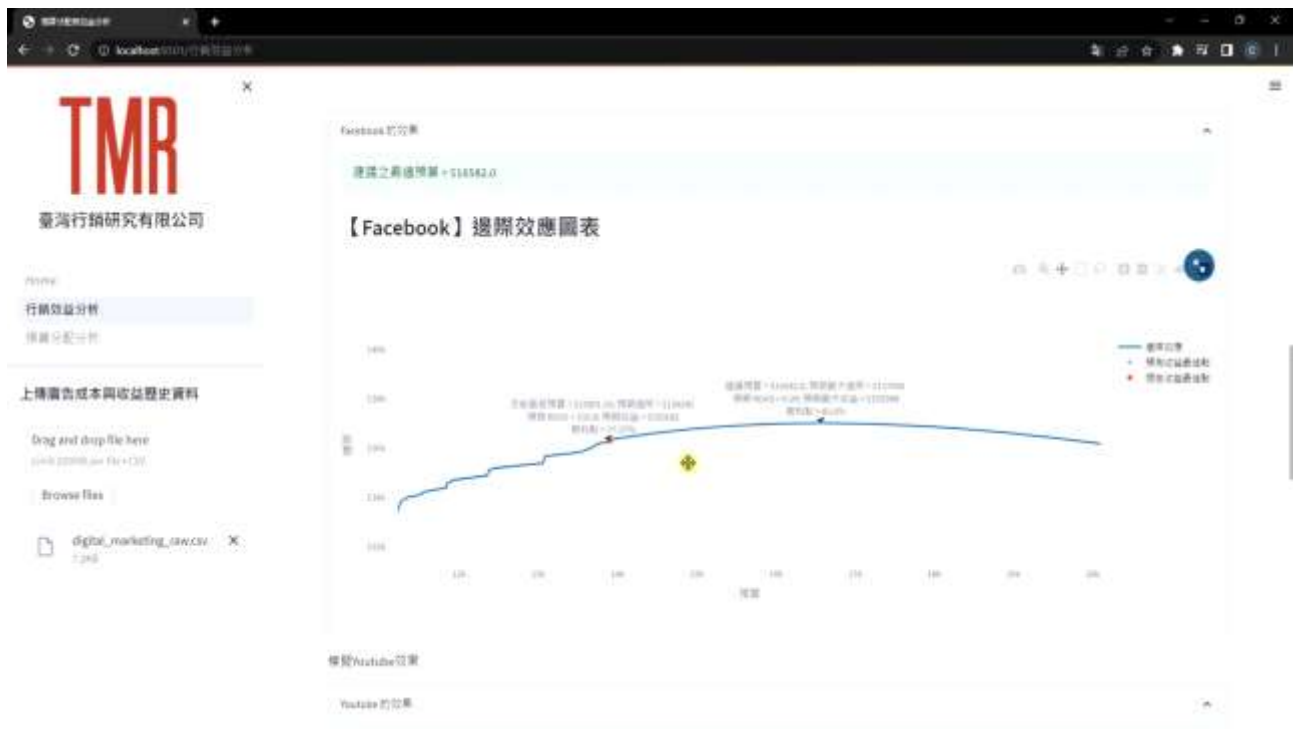


圖 27. Facebook動態市場飽和效應圖表

同樣，YouTube與Magazine的效果也能一覽無遺，如圖28與29所示。

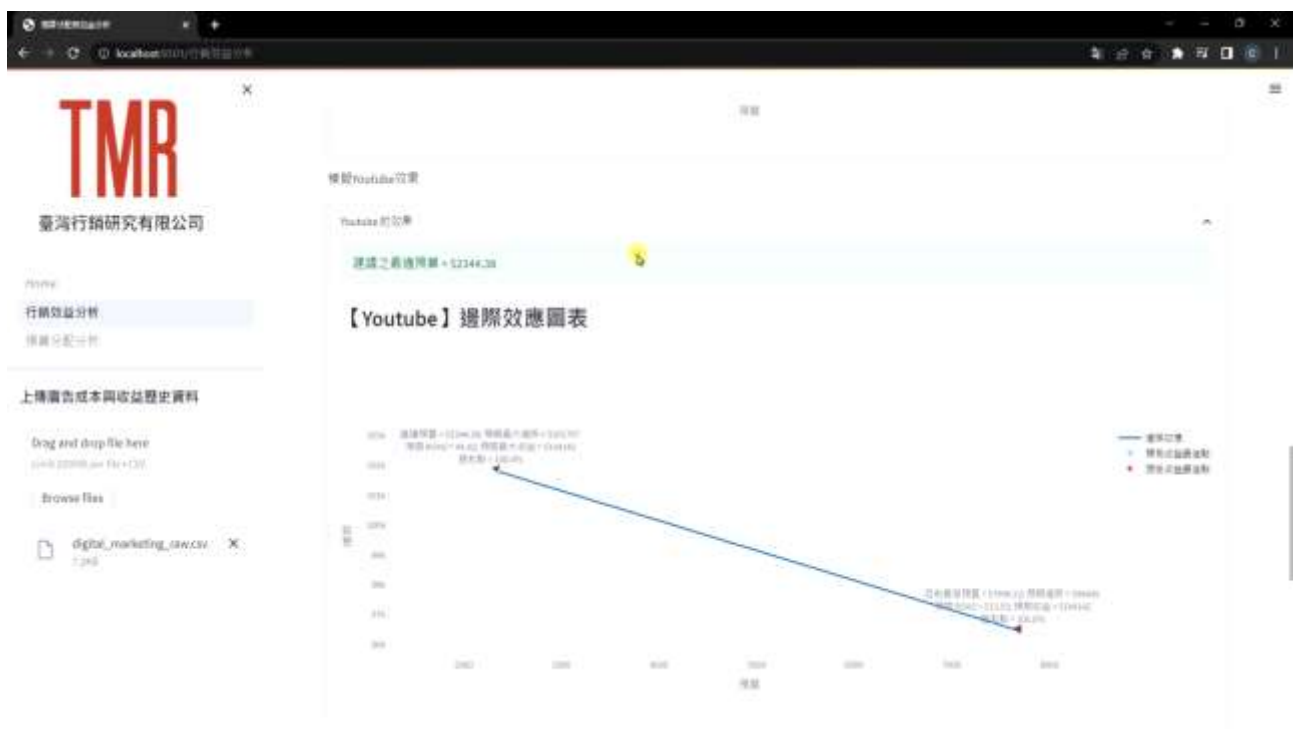


圖 28. YouTube最適預算圖表

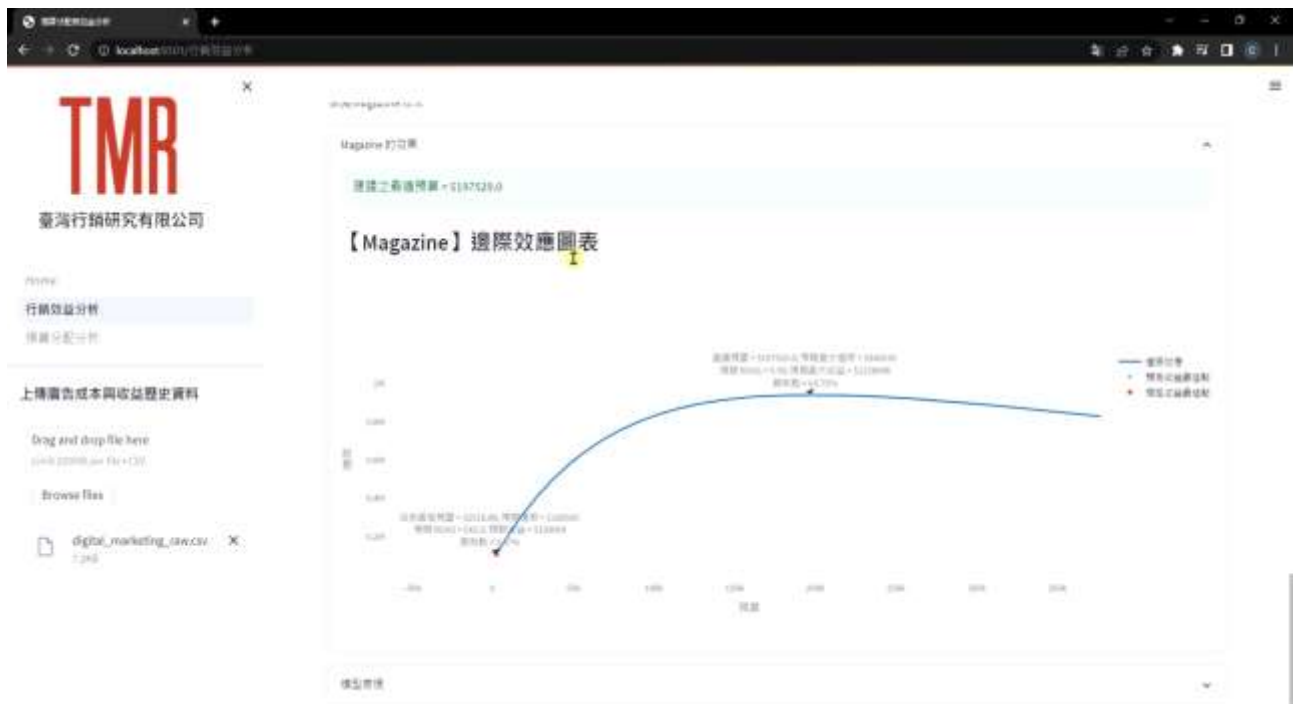


圖 29. YouTube動態市場飽和效應圖表

在模型表現上，一樣可以使用來預測後續的銷售狀況，如圖30所示。



圖 30. 行銷迴歸模型的銷售預測動態圖表

也可以評估每週營收與信賴區間的上下界，同時可以查看模型表現與誤差部分，以本次案例而言，我們得知預測準確率為近95%且加入了遞延效應與市場飽和效應後的行銷迴歸模型能解釋94%的營收來源，如圖31所示。



圖 31. 模型表現表

接著就來到了Jasper最引頸期盼的「自動預算分配」環節，在圖32中可以輸入Jasper的欲分配的總預算，此例為65,949元，因為每一組行銷通路很難只投少量的費用，例如：1元，所以為了因應各行銷通路的最低的成本投入需求，所以在本例的其他機器學習模型的設計上也有將成本的上、下限給考量進去。甚至我們最高預算部分則採納我們在圖27至29的最適預算自動填入其中，讓Jasper不用花費心力思考每一個通路最高要給多少預算，反而直接請演算法幫Jasper決定。

TMR
臺灣行銷研究有限公司

Home
效能效益分析
預算分配分析

請上傳人工預算表(可選)
[drag and drop file here
or use 1024KB per file x 10]
Browse files

預算分配分析

本處是預算分配分析，將行銷效益分析的結果進一步針對人工預算學數據進行預算分配。

請輸入你的總預算
65949

請輸入最低facebook預算
100

請輸入最高facebook預算
16582

請輸入最低youtube預算
1000

請輸入最高youtube預算
2344

請輸入最低magazine預算
1641

請輸入最高magazine預算
197529

預測幾周的預算?

圖 32. 自動預算分配輸入表

至於要分配到多長時間，在圖33中Jasper也可以自己輸入想要分配預算的週數，演算法即自動會幫Jasper善用65,949元預算，進而找出最大化的獲利。

TMR
臺灣行銷研究有限公司

Home
效能效益分析
預算分配分析

請上傳人工預算表(可選)
[drag and drop file here
or use 1024KB per file x 10]
Browse files

請輸入最低facebook預算
100

請輸入最高facebook預算
16582

請輸入最低youtube預算
1000

請輸入最高youtube預算
2344

請輸入最低magazine預算
1641

請輸入最高magazine預算
197529

預測幾周的預算?
8

請輸入預算分配演算法需要迭代的次數
30

請輸入預算分配演算法的母體規模
100

應用預算分配策略

圖 33. 可輸入想要分配預算的週數

接著Jasper就可點擊圖34的「應用預算分配策略」的按鈕。

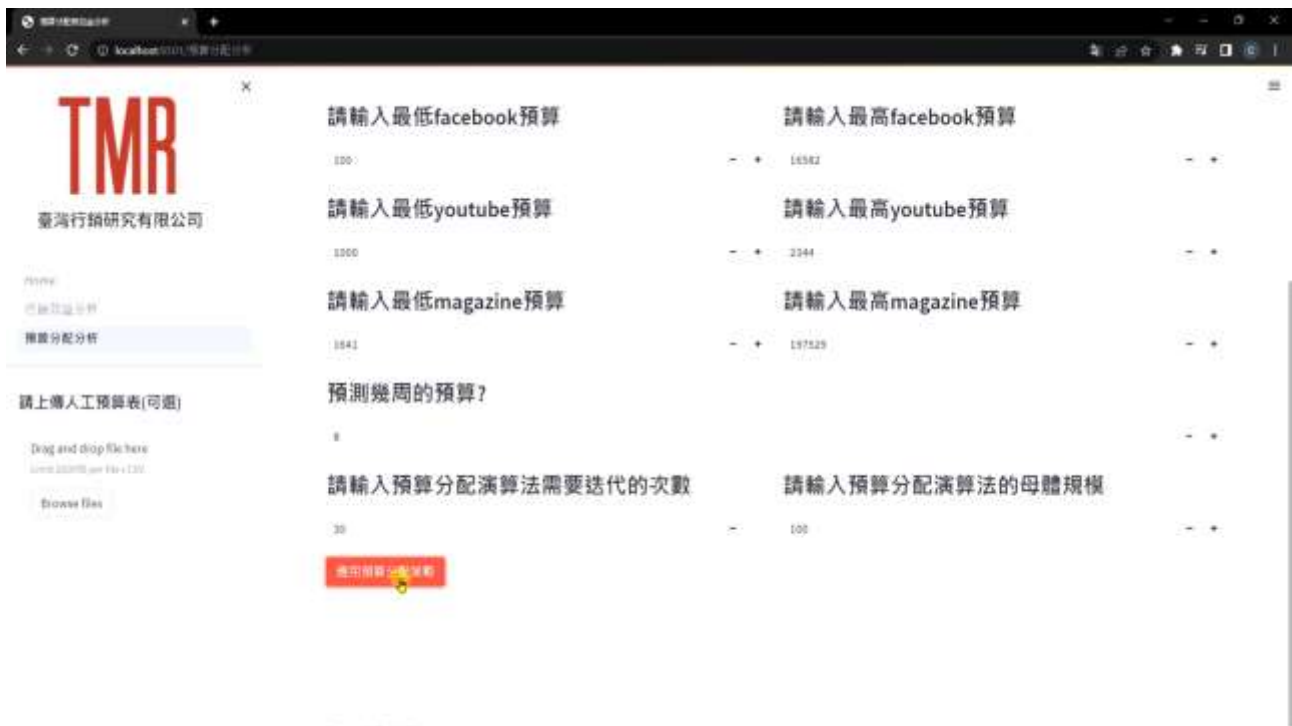


圖 34. 點擊應用預算分配策略按鈕，開始自動化預算分配

演算法就會在圖35自動開始找尋最佳的預算分配策略

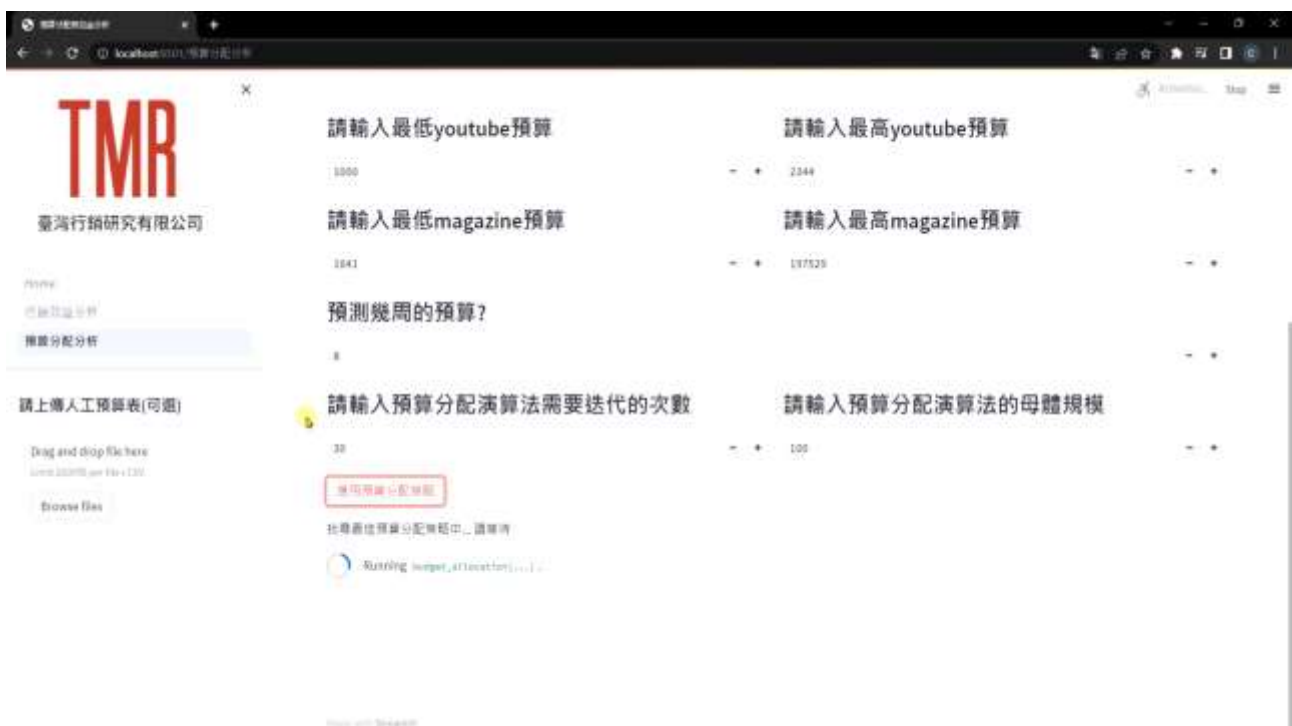


圖 35. 自動化預算分配演算

首先映入眼簾的是圖36的預算成本結果，左圖的「人工預算分配」與右圖的「機器學習優化預算分配」，可以看到人工分配大多集中在數位通路，但根據最大化營

收的演算法分析來說，則可見大多預算選擇會放在Magazine，再來則是YouTube與Facebook。



圖 36. 「人工預算分配」與「機器學習優化預算分配」成本架構圖

圖37的左表則是這八週來人工預算分配的配比，右表則是演算法建議的預算配比。



圖 37. 「人工預算分配」與「機器學習優化預算分配」成本架構表

圖38是人工預算與機器學習預算所產出的財務結果比較圖，左圖的人工預算分配可以獲得的ROAS為18左右，營收為120萬左右；反觀右圖的機器學習優化預算分配可以獲得的ROAS為24.5，真實ROAS則會落在22.15與26.93的區間，營收為161萬左右，真實營收則會落在146萬與178萬的區間。

由此可知，本機器學習模型在這8週的預算分配下，有95%的信心水準表現的至少會比人工預算分配的結果還要來得更好。



圖 38. 人工預算與機器學習預算財務結果比較圖

Jasper回饋：「哦哦！這真實太棒了！這就是我想要的預算分配智慧系統啊！」

Jasper繼續詢問：「那具體好多少呢？」

可從圖39了解到Jasper若使用機器學習預算分配策略，則有95%的信心其真實營收會，遠比自行人工預算分配策略所產出營收還要高26萬到58萬。



圖 39. 人工與機器學習優化預算分配策略收益差距圖表

Jasper回饋：「這套機制真的太棒了！這樣我之後就可以判斷不同商品在不同的行銷通路廣告下，來比較人工與機器學習的建議，進而找到最適的預算分配方法！」

References

- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*.
- Danaher, P. J., Bonfrer, A., & Dhar, S. (2008). The Effect of Competitive Advertising Interference on Sales for Packaged Goods. *Journal of Marketing Research*, 45(2), 211-225. <https://doi.org/10.1509/jmkr.45.2.211>
- Köhler, C., Mantrala, M. K., Albers, S., & Kanuri, V. K. (2017). A Meta-Analysis of Marketing Communication Carryover Effects. *Journal of Marketing Research*, 54(6), 990-1008. <https://doi.org/10.1509/jmr.13.0580>
- Liu, Y. P., & Yang, R. (2009). Competing Loyalty Programs: Impact of Market Saturation, Market Share, and Category Expandability [Article]. *Journal of Marketing*, 73(1), 93-108. <https://doi.org/10.1509/jmkg.73.1.93>
- Redman, T., & Hoerl, R. (2019). Most analytics projects don't require much data. *Harvard Business Review*, 3. <https://hbr.org/2019/10/most-analytics-projects-dont-require-much-data>